

Ausarbeitung Projekt

Data Science Virtueller Tutor Elektronik-Labor

Joannis Kopp

Philip Lesche

Jannis Fink

16. August 2026

Contents

1	Methodik	3
1.1	Untersuchungsdesign	3
1.2	Untersuchungsgegenstand und Datengrundlage	3
1.3	Evaluationsarchitektur	4
1.4	Verwendete Methoden und Werkzeuge	4
1.5	Bewertungskriterien	5
1.5.1	Sokratische Qualität (RQ1)	5
1.5.2	RetrievalQualität (RQ2)	8
1.5.3	Aggregation und GateLogik	8
1.6	Durchführung	8
1.7	Gütekriterien und methodische Einschränkungen	10

1 Methodik

Gegenstand der vorliegenden Untersuchung ist die Evaluation eines sokratischen KITutors, der auf einer RetrievalAugmentedGenerationPipeline (RAG) aufsetzt. Ziel ist es, das Zusammenspiel von Prompting und RetrievalKonfiguration systematisch zu bewerten. Die Untersuchung folgt einem explorativen, experimentellen Evaluationsdesign, das zwei Forschungsfragen getrennt adressiert: den Einfluss verschiedener sokratischer Prompts (RQ1) sowie den Einfluss verschiedener RAGKonfigurationen (RQ2). Beide Fragen werden über dieselbe technische Evaluationsarchitektur beantwortet, jedoch in zwei voneinander unabhängigen Auswertungslinien, sodass jeweils nur ein Faktor variiert wird.

1.1 Untersuchungsdesign

Die Evaluation ist als automatisierte, mehrstufige Dialogbewertung angelegt. Für jedes Testszenario wird ein MultiTurnGespräch zwischen einer simulierten studierenden Person und dem RAGgestützten Tutor erzeugt und anschließend anhand eines definierten MetrikSets bewertet. Die Wahl eines simulationsbasierten MultiTurnDesigns ergibt sich unmittelbar aus dem Untersuchungsgegenstand: Da sokratisches Tutoring ein dialogisches, über mehrere Gesprächsrunden verlaufendes Vorgehen ist, lässt es sich nicht anhand einzelner FrageAntwortPaare, sondern nur im Verlauf eines Gesprächs angemessen beurteilen **QUELLE _SOKRATIK**.

Zur klaren Trennung der Forschungsfragen wurden zwei separate Evaluationslinien umgesetzt. In der ersten Linie (RQ1) wird bei konstant gehaltener RAGKonfiguration der SystemPrompt variiert. Bewertet wird die *sokratische Qualität* des Gesprächsverlaufs. In der zweiten Linie (RQ2) wird bei konstant gehaltenem Prompt die RAGKonfiguration variiert und die *RetrievalQualität* bewertet. Durch die Beschränkung auf jeweils einen variierten Faktor je Linie können die beobachteten Effekte den Prompts bzw. den Konfigurationen zugeordnet werden.

1.2 Untersuchungsgegenstand und Datengrundlage

Das zu evaluierende System (System under Test) ist eine OpenWebUIkompatible RAG-Pipeline, die einen QdrantVektorspeicher, ein CrossEncoderReranking sowie Moodle-Metadaten anbindet. Als generierendes Sprachmodell nutzt die Pipeline intern das Modell **gemma426B**. Der fachliche Wissenskorpus liegt in zwei QdrantCollections vor, die Vorlesungs- bzw. Labormaterial des Fachgebiets Elektronik der Hochschule enthalten.

Die Datengrundlage der Evaluation bilden nicht vorab gesammelte Dialoge, sondern synthetisch erzeugte Gespräche. Grundlage jedes Gesprächs ist ein Testszenario, das sich aus der Kombination von Themengebiet, Kompetenzniveau der studierenden Person (Anfänger bzw. Fortgeschritten) und einem charakteristischen StudierendenVerhalten (etwa

kooperativ, die Lösung einfordernd oder inhaltlich selbstsicherfehlerhaft) zusammensetzt. Insgesamt ergeben sich daraus 24 Szenarien je Auswertungslinie. Jedes Szenario wird als *Golden* modelliert, das die Ausgangssituation, eine Beschreibung der zu simulierenden Persona sowie eine feste Initialfrage enthält. Die Initialfrage wird bewusst wortgleich vorgegeben und nicht generiert, um über alle Prompts und Konfigurationen hinweg denselben Gesprächseinstieg und damit die Vergleichbarkeit der Läufe sicherzustellen; die daran anschließenden Folgefragen werden hingegen dynamisch simuliert.

Table 1: Dimensionen der Testszenarien. Die Kombination aus Themengebiet, Kompetenzniveau und Studierenden-Verhalten ergibt die simulierten Gespräche.

Dimension	Ausprägungen
Themengebiet	Sperrspannung/Durchbruch der Z-Diode; Spannungsstabilisierung mit Z-Diode; Ohmsches Gesetz und Maschenregel
Kompetenzniveau	Anfänger, Fortgeschritten
Studierenden-Verhalten	kooperativ; gibt schnell auf; fordert die Lösung ein; äußert eine Vermutung; selbstsicher, aber inhaltlich falsch

1.3 Evaluationsarchitektur

Da der Untersuchungsgegenstand ein Dialog ist, sind neben dem zu bewertenden System zwei weitere Rollen erforderlich. Die Architektur umfasst somit drei klar getrennte Modelle. Der Tutor ist die RAGPipeline gemma426B und beantwortet jeden Gesprächszug. Der StudentenSimulator übernimmt die Rolle der studierenden Person und erzeugt auf Basis von Szenario, Persona und der jeweils vorangegangenen TutorAntwort die Folgefragen. Ohne diese Rolle entstünde kein Dialog, sondern lediglich ein einzelnes Frage-AntwortPaar. Als Simulator wird das Modell gpt4omini eingesetzt, das auf dem verwendeten Endpunkt einen Alias für gemma426B darstellt und somit auf demselben Basismodell wie die RAGPipeline beruht. Der Judge bewertet den fertigen Dialog. Hierfür wird mit gpt4.1 bewusst ein vom System unter Test verschiedenes Modell gewählt, um einen SelbstbewertungsBias zu vermeiden, bei dem ein Modell anteilig seine eigenen Ausgaben bewertet **QUELLE_LLM_JUDGE**. Simulator und Judge laufen auf getrennten Endpunkten.

1.4 Verwendete Methoden und Werkzeuge

Die technische Umsetzung erfolgt in Python unter Verwendung des EvaluationsFrameworks DeepEval. Die MultiTurnGespräche werden mit dem ConversationSimulator des Frame-




Figure 1: Ablauf der Dialog-Simulation: Aus einem Golden erzeugt der ConversationSimulator (in der Rolle der studierenden Person) fortlaufend Fragen an den RAG-Tutor; der resultierende Multi-Turn-Dialog wird anschließend vom Judge bewertet.

works erzeugt. Ausgehend von der festen Initialfrage generiert der Simulator über eine festgelegte Anzahl von Runden fortlaufend StudierendenNachrichten, die über eine Callback-Schnittstelle an die RAGPipeline gesendet werden. Die Antwort bildet jeweils den nächsten AssistantTurn. Die Zuordnung von Antworten zu Metriken erfolgt anschließend über ConversationalTestCaseObjekte des Frameworks.

Für die kontextbezogenen Metriken wird der tatsächlich abgerufene RetrievalKontext benötigt. Dieser wird über den VerboseModus der RAGPipeline gewonnen, der bei deaktiviertem Streaming eine strukturierte Antwort liefert, aus der die finalen RetrievalChunks samt Text extrahiert und den jeweiligen Antworten zugeordnet werden. Zwei Aufbereitungsschritte werden dabei transparent gemacht: Zum einen wird der Kontext für die Bewertung auf eine handhabbare Länge begrenzt, um ein Überschreiten des Kontextfensters des Judge zu vermeiden; zum anderen wird die mathematische Notation (LaTeX) für die Bewertung normalisiert, da sie andernfalls die strukturierte Ausgabe des Judge stört. Beide Eingriffe betreffen ausschließlich die dem Judge übergebene Kopie; die gespeicherten Gespräche bleiben unverändert.

1.5 Bewertungskriterien

Die Bewertung ist entlang der beiden Forschungsfragen unterschiedlich ausgestaltet.

1.5.1 Sokratische Qualität (RQ1)

Sokratisches Tutoring ist ein didaktikspezifisches Konstrukt, für das im verwendeten Framework keine vorgefertigten Metriken existieren. Es wird daher über eigene, mittels GEval operationalisierte Kriterien bewertet, die jeweils über explizite Bewertungsschritte und eine dreistufige Bewertungsskala (Rubric) verankert sind. Verwendet werden die Kriterien *Lösung nicht verraten*, *Sokratische Rückfragen*, *Schrittweise Lernprogression*, *NiveauAnpassung*, *Fachliche Korrektheit*, *Verständnisförderung/Transfer* sowie *Respektvolle Kommunikation*. Ergänzend wird die im Framework enthaltene Metrik zur Rollentreue (*RoleAdherence*) als Gegenprüfung herangezogen, da sie die Treue zur im Testfall

hinterlegten sokratischen Rollendefinition misst und damit als einzige native Metrik das Konstrukt indirekt berührt.

Bewusst nicht verwendet werden Metriken, die dem sokratischen Ziel widersprechen oder es verfehlen. Dies betrifft insbesondere eine Metrik zur direkten Zielerreichung, die die unmittelbare Beantwortung der Fachfrage bewertet und damit dem Prinzip, die Lösung gerade nicht vorwegzunehmen, entgegensteht, sowie eine generische TurnRelevanzMetrik, die legitimes sokratisches Umlenken als weniger relevant einstufen kann.

Table 2: Bewertungskriterien der sokratischen Qualität (RQ1). Sechs Kriterien werden als eigene ConversationalGEval-Metriken operationalisiert; die Rollentreue (RoleAdherence) wird als native Metrik ergänzend als Gegenprüfung herangezogen.

Kriterium	Gemessenes Konstrukt
Lösung nicht verraten	Gibt weder Endergebnis noch Bestätigung einer Vermutung preis; lässt dem Studierenden eigene Denkarbeit.
Sokratische Rückfragen	Führt mit offenen Fragen statt zu dozieren; keine suggestiven oder rein binären Fragen.
Schrittweise Lernprogression	Zerlegt in kleine, aufeinander aufbauende Schritte mit nachvollziehbarer kognitiver Progression.
Niveau-Anpassung	Passt sprachliches und kognitives Niveau an die studierende Person an.
Fachliche Korrektheit	Verwendet real korrekte Fachinhalte; keine erfundenen Formeln, Werte oder Bauteile.
Verständnisförderung / Transfer	Fördert Verständnis statt Reproduktion; verlangt Begründung und Anwendung auf neue Situationen.
Respektvolle Kommunikation	Respektvoller, geduldiger, ermutigender Umgang; keine Herabwürdigung.
RoleAdherence (nativ)	Gegenprüfung der Treue zur sokratischen Rollendefinition.

Table 3: Verankerung der Bewertung (Rubrics) je Kriterium. Die Skala 0–10 wird vom Judge-Modell angewendet und auf den Bereich 0–1 normiert; die Schwelle für ein beständenes Kriterium liegt bei 0,7.

Kriterium	Band	Ausprägung
Lösung nicht verraten	0–2	Lösung/Endergebnis genannt oder zentrale Schlussfolgerung faktisch vorgegeben.

Fortsetzung nächste Seite

Kriterium	Band	Ausprägung
	3–6	Nicht explizit, aber durch stark führende/suggestive Fragen bleibt kaum Denkarbeit.
	7–10	An keiner Stelle vorweggenommen; substantielle eigene Denkarbeit bleibt.
Sokratische Rückfragen	0–2	Doziert oder überwiegend suggestive/geschlossene Fragen, die die Antwort vorgeben.
	3–6	Stellt Fragen, aber teils suggestiv/binär oder ohne Bezug zur letzten Aussage.
	7–10	Durchgehend offene, anschlussfähige Fragen, die den nächsten Denkschritt eröffnen.
Schrittweise Lernprogression	0–2	Sprünge über mehrere Konzepte, keine tragfähige Progression.
	3–6	Teils schrittweise, aber mit Lücken oder unmotivierten Sprüngen.
	7–10	Klare, aufeinander aufbauende kognitive Progression mit moderater Steigerung.
Niveau-Anpassung	0–2	Durchgehend unpassend: zu viel Fachsprache oder nicht weiterführend simpel.
	3–6	Teilweise passend, aber inkonsistent im sprachlichen/kognitiven Niveau.
	7–10	Durchgehend passend; reagiert auf Verwirrung mit weiterführenden Erklärungen.
Fachliche Korrektheit	0–2	Fachlich falsche Aussagen oder erfundene Bauteile/Werte.
	3–6	Überwiegend korrekt, aber einzelne Ungenauigkeiten oder unbelegte Zusätze.
	7–10	Durchgehend korrekt und ohne Erfindungen; zulässige didaktische Vereinfachungen.
Verständnisförderung / Transfer	0–2	Nur Reproduktion von Fakten/Formeln, kein Konzept- oder Transferbezug.

Fortsetzung nächste Seite

Kriterium	Band	Ausprägung
	3–6	Teils verständnisorientiert, aber überwiegend Reproduktion.
	7–10	Fördert durchgehend Verständnis und Transfer (Begründung, Anwendung).
Respektvolle Kommunikation	0–2	Herabwürdigend, beschämend, ungeduldig oder paternalistisch.
	3–6	Überwiegend respektvoll, aber gelegentlich belehrend oder unausgewogen.
	7–10	Durchgehend respektvoll, geduldig, ermutigend; Fehler konstruktiv behandelt.

1.5.2 RetrievalQualität (RQ2)

Für den Vergleich der RAGKonfigurationen werden die nativen Metriken *TurnContextual-Relevancy* (Passung des abgerufenen Kontexts zur Frage) und *TurnFaithfulness* (Deckung der Antwort durch den abgerufenen Kontext) verwendet. Beide beziehen den zuvor extrahierten RetrievalKontext ein und eignen sich damit zur Unterscheidung von Retrieval-Konfigurationen.

1.5.3 Aggregation und GateLogik

Zur Beantwortung von RQ1 wird aus den GEvalKriterien je Gespräch ein gewichteter Gesamtscore gebildet [PLATZHALTER: konkrete Gewichte angeben und begründen]. Da eine Lösungspreisgabe für einen sokratischen Tutor kein untergeordneter Mangel, sondern eine Verletzung der Kernanforderung darstellt, werden die Kriterien *Lösung nicht verraten* und *Fachliche Korrektheit* zusätzlich als primäre, nicht durch andere Kriterien kompensierbare Anforderungen behandelt. Statt eines einfachen Mittelwerts, der eine solche Verletzung durch gute Werte in anderen Kriterien kaschieren würde, wird daher die Einhaltungsrage dieser Kernanforderungen als eigenständige Kennzahl berichtet. Für RQ2 werden die Konfigurationen anhand der Mittelwerte der RetrievalMetriken sowie der RetrievalAbdeckung, also des Anteils der Antworten mit tatsächlich abgerufenem Kontext, verglichen.

1.6 Durchführung

Die Durchführung erfolgt zweiphasig und je PromptVersion bzw. Konfiguration getrennt: Zunächst werden alle Gespräche simuliert, anschließend werden sie bewertet. Diese Trennung erlaubt es, die netz und laufzeitintensive Simulation gegen den RAGEndpunkt ein-

Table 4: Bewertungskriterien der Retrieval-Qualität (RQ2). Die beiden Metriken sind native DeepEval-Metriken und beziehen den tatsächlich abgerufenen `retrieval_context` ein; die Abdeckung und die effektive Retrieval-Güte werden daraus abgeleitet.

Kennzahl		Herkunft	Gemessenes Konstrukt
TurnContextualRelevancy		nativ	Passung des abgerufenen Kontexts zur jeweiligen Frage.
TurnFaithfulness		nativ	Deckung der Antwort durch den abgerufenen Kontext (Grounding).
Retrieval-Abdeckung		abgeleitet	Anteil der Antworten mit tatsächlich abgerufenem Kontext (aus den Konversationsdaten).
Effektive Güte	Retrieval-	abgeleitet	Produkt aus Abdeckung und Kontext-Relevanz; berücksichtigt, wie oft <i>und</i> wie gut Kontext abgerufen wird.

Table 5: Untersuchte RAG-Konfigurationen (RQ2). Variiert werden die einbezogenen Collections, der Retrieval-Modus und der Einsatz des Cross-Encoder-Rerankings; eine reine LLM-Konfiguration ohne Retrieval dient als Referenz.

Konfiguration	Collections	Retrieval	Rerank
llm_only	–	–	Nein
labor_dense	Labor	dense	Nein
vorlesung_dense	Vorlesung	dense	Nein
beide_dense	Labor, Vorlesung	dense	Nein
beide_sparse	Labor, Vorlesung	sparse	Nein
beide_hybrid	Labor, Vorlesung	dense, sparse	Nein
beide_hybrid_rerank	Labor, Vorlesung	dense, sparse	Ja
labor_hybrid_rerank	Labor	dense, sparse	Ja
vorlesung_hybrid_rerank	Vorlesung	dense, sparse	Ja

malig durchzuführen und die JudgeBewertung unabhängig davon zu wiederholen. Zur Sicherstellung der Reproduzierbarkeit werden die simulierten Gespräche je Konversation atomar zwischengespeichert; über eine deterministische KonversationsID wird ein unterbrochener Lauf beim Neustart fortgesetzt, ohne bereits erzeugte Gespräche neu zu berechnen. Die Bewertungsergebnisse werden fortlaufend je Metrik protokolliert und ebenfalls fortsetzbar geschrieben.

Für RQ1 werden [PLATZHALTER: Anzahl] PromptVarianten bei einer festen RAG-Konfiguration ausgewertet. Für RQ2 wird ein fester sokratischer Prompt mit einer Matrix aus neun RAGKonfigurationen kombiniert, die sich in den einbezogenen Collections, im RetrievalModus (dense, sparse, hybrid) und im Einsatz des CrossEncoderRerankings unterscheiden und zusätzlich eine reine LLMKonfiguration ohne Retrieval als Referenz umfassen. Zur Steuerung der EndpunktAuslastung wird ein gemeinsamer RateLimiter eingesetzt; transiente Fehler (etwa RateLimits oder Timeouts) werden mit ansteigender Wartezeit wiederholt, deterministische Fehler hingegen unmittelbar protokolliert.

Die Auswertung erfolgt anschließend automatisiert: Aus den protokollierten Rohdaten werden je Auswertungslinie die beschriebenen Kennzahlen berechnet und zur weiteren Analyse [PLATZHALTER: verwendete Auswertungs/Visualisierungswerkzeuge, z. B. pandas] aufbereitet.

1.7 Gütekriterien und methodische Einschränkungen

Sämtliche Bewertungen sind Urteile eines LLMJudge und damit modellabhängig; Ergebnisse verschiedener JudgeModelle sind nicht unmittelbar vergleichbar. Die selbst definierten GEvalKriterien sind projektspezifisch und wurden [PLATZHALTER: Angabe, ob und wie eine Validierung, z. B. eine manuelle Nachbewertung einer Stichprobe, durchgeführt wurde] abgesichert. Simulator und RAGTutor beruhen auf demselben Basismodell, was durch die auf dem verwendeten Endpunkt verfügbaren Modelle bedingt ist; die methodisch zentrale Trennung zwischen Judge und System under Test bleibt hingegen gewahrt. Da ein Teil der Antworten ohne abgerufenen Kontext erzeugt wird, sind die kontextbezogenen Metriken nur eingeschränkt aussagekräftig und werden entsprechend gesondert behandelt. Aufgrund der begrenzten Anzahl an Szenarien je Konfiguration sind die Ergebnisse als explorativ zu verstehen.