

Ausarbeitung Projekt

Data Science Virtueller Tutor Elektronik-Labor

Joannis Kopp (1350403)

Philip Lesche (1682942)

Jannis Fink (1684087)

31. August 2026

Contents

1	Einleitung	4
2	Grundlagen	6
2.1	Sokratische Didaktik und Tutoring	6
2.2	Retrieval-Augmented Generation	7
2.2.1	Sparse und Dense Retrieval	7
2.2.2	Hybrid Retrieval und Reciprocal Rank Fusion	8
2.2.3	Cross-Encoder-Reranking	9
2.3	Evaluation LLM-basierter Dialogsysteme	10
2.3.1	LLM-as-a-Judge	10
2.3.2	Multi-Turn-Evaluation und ConversationalTestCase	10
2.3.3	Conversational G-Eval	11
2.3.4	Vordefinierte Multi-Turn-Metriken	11
3	Untersuchungsgegenstand	13
3.1	Die RAG-Pipeline	13
3.2	Die Prompt-Varianten für RQ1	15
3.3	RAG-Konfigurationen für RQ2	16
4	Methodik	18
4.1	Untersuchungsdesign	18
4.2	Untersuchungsgegenstand und Datengrundlage	18
4.3	Evaluationsarchitektur	19
4.4	Verwendete Methoden und Werkzeuge	19
4.5	Bewertungskriterien	20
4.5.1	Sokratische Qualität (RQ1)	20
4.5.2	Retrieval-Qualität (RQ2)	21
4.6	Durchführung	22
4.7	Gütekriterien und methodische Einschränkungen	23
4.8	Projekt-Setup	23
5	Ergebnisse	24
5.1	RQ1 – Vergleich der Prompt-Varianten	24
5.1.1	Ergebnisse je Kriterium	24
5.1.2	Ergebnisstabilität und Streuung	26
5.1.3	Ergebnisse je Prompt-Variante	26
5.2	Querschnitt: Verhalten, Thema und Niveau	27
5.2.1	Verteilung der Einzelscores	27
5.2.2	Ergebnisse nach Studentenverhalten	28

5.2.3	Fallbeispiele zu den Unter-Schwellen-Werten	29
5.3	RQ2 – Vergleich der RAG-Konfigurationen	30
5.3.1	Datenlage und Retrieval-Abdeckung	30
5.3.2	Kontextbezogene Metriken und effektive Scores	32
6	Diskussion	35
6.1	Beantwortung von RQ1	35
6.2	Beantwortung von RQ2	35
6.3	Metrik-Mismatch bei unterschiedlichen Studenten Verhaltensweisen	37
6.4	Datenqualität und Aussagekraft der RQ2-Ergebnisse	37
6.5	Limitationen	38
	References	39
A	Verwendete Prompt-Varianten	42
A.1	Baseline ohne Systemprompt	42
A.2	Minimaler sokratischer Prompt	42
A.3	Strukturierter sokratischer Prompt	42
A.4	Domänenspezifischer In-Lab-Tutorprompt	44

1 Einleitung

Large Language Models ermöglichen die Umsetzung dialogbasierter Tutorsysteme, deren Verhalten über Instruktionen in natürlicher Sprache gesteuert und durch zusätzliche Wissensquellen erweitert werden kann. Für den Einsatz als virtueller Tutor im Elektroniklabor reicht es jedoch nicht aus, fachlich korrekte Antworten zu erzeugen. Der Tutor soll Studierende bei der eigenständigen Auseinandersetzung mit einer Problemstellung unterstützen, anstatt ihnen unmittelbar eine fertige Lösung vorzugeben. Gleichzeitig muss der für die Antwortgenerierung bereitgestellte fachliche Kontext zur jeweiligen Fragestellung passen und von dem Sprachmodell angemessen genutzt werden.

Die vorliegende Arbeit untersucht einen LLM-basierten virtuellen Tutor für das Elektroniklabor, der ein sokratisches Tutorverhalten mit einer Retrieval-Augmented-Generation-Pipeline verbindet. Das Tutorverhalten wird dabei durch einen Systemprompt gesteuert, während die RAG-Pipeline fachliche Inhalte aus Vorlesungs- und Labormaterialien abrufen und dem Sprachmodell als zusätzlichen Kontext bereitstellt. Die resultierende Qualität des Systems hängt damit sowohl von der Ausgestaltung der Instruktionen als auch von der Konfiguration des Retrievals ab.

Ziel der Untersuchung ist es, diese beiden Einflussfaktoren getrennt voneinander zu evaluieren. Daraus ergeben sich zwei Forschungsfragen:

- RQ1:** Welchen Einfluss hat die Ausgestaltung des Systemprompts auf die sokratische Qualität des Tutorverhaltens?
- RQ2:** Welchen Einfluss hat die Konfiguration der RAG-Pipeline auf die Qualität des bereitgestellten Retrieval-Kontexts und dessen Nutzung bei der Antwortgenerierung?

Zur Beantwortung von RQ1 werden vier Prompt-Varianten mit unterschiedlichem Grad der didaktischen Steuerung miteinander verglichen. Diese reichen von einer Baseline ohne sokratische Instruktion über einen minimalen sokratischen Prompt bis zu einem strukturierten sokratischen Prompt und einem domänenspezifischen In-Lab-Tutorprompt. Die RAG-Konfiguration wird innerhalb dieser Auswertungslinie konstant gehalten, sodass die beobachteten Unterschiede auf die Gestaltung des Systemprompts zurückgeführt werden können.

RQ2 untersucht dagegen unterschiedliche Konfigurationen der RAG-Pipeline bei konstant gehaltenem Systemprompt. Variiert werden die verwendete Wissensbasis, das Retrieval-Verfahren sowie der Einsatz eines Cross-Encoder-Rerankings. Betrachtet werden Dense, Sparse und Hybrid Retrieval mit Vorlesungsinhalten, Laborinhalten oder deren Kombination. Ergänzend dient eine Variante ohne Retrieval als Referenz.

Die Evaluation erfolgt anhand synthetisch erzeugter Multi-Turn-Gespräche zwischen einer simulierten studierenden Person und dem virtuellen Tutor. Die Testszenarien unterscheiden sich hinsichtlich des Themengebiets, des Kompetenzniveaus und des simulierten

Studierendenverhaltens. Die resultierenden Gespräche werden anschließend automatisiert mit DeepEval bewertet. Für RQ1 werden anwendungsspezifische Kriterien der sokratischen Qualität sowie die Rollentreue des Tutors betrachtet. RQ2 wird anhand der Relevanz des abgerufenen Kontexts, der Übereinstimmung der Tutorantworten mit diesem Kontext und der Retrieval-Abdeckung untersucht. Die beiden Forschungsfragen werden in getrennten Auswertungslinien betrachtet, sodass jeweils nur der zu untersuchende Faktor variiert wird.

Die Arbeit ist wie folgt aufgebaut: Kapitel 2 legt die theoretischen Grundlagen des sokratischen Tutorings, der Retrieval-Augmented Generation und der Evaluation LLM-basierter Dialogsysteme dar. Anschließend werden der untersuchte Tutor, die RAG-Pipeline sowie die Prompt- und Retrieval-Varianten beschrieben. Das Methodikkapitel erläutert das Untersuchungsdesign, die Datengrundlage, die Evaluationsarchitektur und die verwendeten Bewertungskriterien. Darauf aufbauend werden die Ergebnisse der beiden Forschungsfragen sowie ergänzende Querschnittsanalysen dargestellt. Abschließend werden die Befunde hinsichtlich der Forschungsfragen eingeordnet und die methodischen Einschränkungen der Evaluation diskutiert.

2 Grundlagen

Für die Entwicklung und Evaluation des virtuellen Tutors sind drei fachliche Grundlagen maßgeblich: das sokratische Tutoring, die Retrieval-Augmented Generation sowie die Evaluation LLM-basierter Dialogsysteme. Die folgenden Abschnitte leiten diese Konzepte her und schaffen damit die Grundlage für die spätere Untersuchung des Tutorsystems.

2.1 Sokratische Didaktik und Tutoring

Die sokratische Methode bezeichnet einen Lehransatz, bei dem Erkenntnis nicht primär durch die Vermittlung fertiger Antworten, sondern durch die eigenständige Auseinandersetzung des Lernenden mit Fragen, Annahmen und Begründungen entwickelt werden soll. Eine für die moderne didaktische Rezeption maßgebliche Ausarbeitung geht auf Leonard Nelson zurück. In seinem 1922 gehaltenen und 1929 veröffentlichten Vortrag *Die sokratische Methode* grenzt Nelson sokratischen Unterricht von einer auf Wissensvermittlung ausgerichteten Lehrform ab. Sein Ziel besteht nicht darin, den Lernenden philosophische Ergebnisse zu übermitteln, sondern sie zum eigenständigen Philosophieren anzuleiten [11]. Erkenntnis soll demnach aus Urteilen hervorgehen, die der Lernende selbst fällt und anschließend auf ihre Voraussetzungen zurückführt. Sokratischer Unterricht wird damit als Unterricht im Selbstdenken verstanden [11].

Diese Zielsetzung bestimmt zugleich die Rolle des Lehrenden. Nelson unterscheidet zwischen einer äußeren Anregung des Denkens und der Übernahme eines fremden Urteils. Während die Anregung des Erkenntnisprozesses erforderlich sein kann, soll der Lehrende vermeiden, das Urteil des Lernenden durch die Vorgabe eigener Lösungen zu ersetzen [11]. Die sokratische Methode zielt somit nicht auf das Stellen möglichst vieler Fragen, sondern auf einen Dialog, der die eigenständige Prüfung des eigenen Denkens ermöglicht.

Eine frühe Übertragung der sokratischen Methode auf computergestütztes Tutoring findet sich bei Stevens und Collins [14]. Mit dem *Why System* beschreiben sie einen sokratischen Tutor, dessen Dialogverhalten durch regelbasierte Tutorstrategien gesteuert wird. Das System fordert Lernende unter anderem zu Vorhersagen und Begründungen auf, greift ihre Antworten in Folgefragen auf und setzt Gegenbeispiele ein, um Annahmen zu überprüfen [14]. Dabei soll die Auswahl der Tutorinterventionen nicht unabhängig voneinander erfolgen, sondern sich an übergeordneten Lernzielen und am erkennbaren Wissensstand des Lernenden orientieren [14]. Die Arbeit zeigt damit, wie sich die sokratische Grundidee des angeleiteten eigenständigen Denkens in ein dialogorientiertes Tutorsystem übertragen lässt.

Eine für die weitere Ausgestaltung eines sokratischen Tutors relevante Konkretisierung liefert Gentry [7]. Er grenzt sokratisches Fragen von der bloßen Abfrage faktischen Wissens ab und verbindet es mit dem Ziel, Lernende zum Nachdenken und zur Entwicklung kritischen Denkens anzuregen [7]. Für lernförderliches Fragen formuliert er fünf Leitlin-

ien: Der Tutor soll erstens den Kenntnisstand des Lernenden berücksichtigen und neues Wissen schrittweise auf vorhandenem Wissen aufbauen. Zweitens sollen Fragen einem Lernzweck dienen und nicht um ihrer selbst willen gestellt werden. Drittens soll das Ziel der Fragen für den Lernenden erkennbar sein. Viertens sollen die für das Lernziel maßgeblichen Inhalte in den Mittelpunkt gestellt werden. Fünftens soll die Gesprächsführung darauf verzichten, Lernende durch Fragen bloßzustellen oder zu demütigen [7].

Für die vorliegende Arbeit wird sokratisches Tutoring entsprechend als dialogische Lehrform verstanden, bei der Fragen nicht der reinen Wissensabfrage dienen, sondern den Lernenden bei der eigenständigen Auseinandersetzung mit einer Problemstellung unterstützen. Der Tutor orientiert seine Fragen am bisherigen Gesprächsverlauf und am erkennbaren Kenntnisstand und führt den Lernenden schrittweise durch den Erkenntnisprozess. Die von Gentry formulierten Leitlinien bilden damit konkrete Anforderungen an das Verhalten des in dieser Arbeit entwickelten LLM-basierten Tutors und werden im weiteren Verlauf bei dessen Evaluation berücksichtigt.

2.2 Retrieval-Augmented Generation

Large Language Models (LLMs) greifen bei der Textgenerierung zunächst auf Wissen zurück, das während des Trainings in ihren Parametern abgebildet wurde. Dieses parametrische Wissen lässt sich jedoch nicht ohne Weiteres aktualisieren oder um anwendungsspezifische Informationen ergänzen. Lewis et al. verbinden deshalb bei der *Retrieval-Augmented Generation* (RAG) ein parametrisches Sprachmodell mit einem externen, nichtparametrischen Wissensspeicher [9]. Vor der Generierung werden für eine Eingabe relevante Inhalte aus diesem Wissensspeicher abgerufen und dem Sprachmodell als zusätzlicher Kontext bereitgestellt. Die erzeugte Antwort kann dadurch neben dem parametrischen Wissen des Modells auf zur Laufzeit abgerufene Informationen zurückgreifen [9]. Ein RAG-System lässt sich damit grundsätzlich in die beiden Schritte Retrieval und anschließende kontextgestützte Generierung unterteilen.

2.2.1 Sparse und Dense Retrieval

Eine zentrale Komponente eines RAG-Systems ist das Retrieval, das aus einer Dokumentensammlung die für eine Anfrage relevanten Inhalte bestimmen soll. Hierfür können unterschiedliche Repräsentationen von Anfrage und Dokument verwendet werden. Klassische Information-Retrieval-Verfahren arbeiten mit *sparse representations*, bei denen Texte über hochdimensionale, überwiegend nicht belegte Merkmalsvektoren repräsentiert werden. Ein etabliertes Verfahren ist BM25, das die Relevanz eines Dokuments unter anderem anhand der Häufigkeit von Suchbegriffen, ihrer Verteilung innerhalb der Dokumentensammlung und der Dokumentlänge bewertet [13]. Sparse Retrieval ist dadurch insbesondere auf lexikalische Übereinstimmungen zwischen Anfrage und Dokument aus-

gerichtet.

Dense Retrieval überführt Anfragen und Dokumente dagegen in niedrigdimensionale, dichte Vektorrepräsentationen. Karpukhin et al. zeigen mit *Dense Passage Retrieval* (DPR), dass Anfragen und Passagen durch getrennte Encoder in einen gemeinsamen Vektorraum abgebildet und anhand der Ähnlichkeit ihrer Repräsentationen verglichen werden können [8]. Das Retrieval ist damit nicht ausschließlich von identischen Begriffen abhängig, sondern kann über gelernte Repräsentationen auch semantische Beziehungen zwischen unterschiedlich formulierten Anfragen und Passagen berücksichtigen.

Sparse und Dense Retrieval weisen damit unterschiedliche Eigenschaften auf. Luan et al. stellen heraus, dass sparse Repräsentationen insbesondere bei der präzisen Erkennung von Begriffen Vorteile besitzen, während Dense-Retrieval-Verfahren semantische Ähnlichkeiten zwischen verwandten Konzepten abbilden können [10]. Die Autoren untersuchen daher auch hybride Ansätze, in denen beide Repräsentationsformen miteinander kombiniert werden.

2.2.2 Hybrid Retrieval und Reciprocal Rank Fusion

Beim Hybrid Retrieval werden Ergebnisse verschiedener Retrieval-Verfahren zusammengeführt. In einem Sparse-Dense-Hybrid können für dieselbe Anfrage beispielsweise ein lexikalisches und ein semantisches Ranking erzeugt werden. Ziel ist es, die unterschiedlichen Eigenschaften beider Retrievalformen gemeinsam zu nutzen [10]. Da beide Verfahren zunächst eigenständige Ranglisten erzeugen, wird ein Verfahren zur Fusion der Rankings benötigt.

Eine Möglichkeit hierfür stellt die von Cormack et al. vorgestellte *Reciprocal Rank Fusion* (RRF) dar [1]. RRF kombiniert die Rangpositionen eines Dokuments über mehrere Ergebnislisten hinweg, ohne dass die von den einzelnen Retrieval-Verfahren erzeugten Scores auf einer gemeinsamen Skala liegen müssen. Der RRF-Score eines Dokuments d ergibt sich aus

$$\text{RRF}(d) = \sum_{r \in R} \frac{1}{k + r(d)}, \quad (1)$$

wobei R die Menge der einbezogenen Rankings, $r(d)$ die Position des Dokuments d im jeweiligen Ranking und k eine Konstante zur Begrenzung des Einflusses hoher Rangpositionen bezeichnet [1]. Dokumente, die in einem oder mehreren Retrieval-Verfahren weit oben eingeordnet werden, erhalten dadurch einen entsprechend höheren kombinierten Score. Auf Basis dieses Scores entsteht eine gemeinsame Rangfolge der Kandidaten.

2.2.3 Cross-Encoder-Reranking

Das erste Retrieval reduziert eine große Dokumentensammlung auf eine begrenzte Menge potenziell relevanter Kandidaten. Diese Kandidaten können anschließend durch ein rechenintensiveres Modell erneut bewertet werden. Nogueira und Cho zeigen am Beispiel von BERT, dass ein Sprachmodell für das Query-basierte Reranking bereits abgerufener Passagen eingesetzt werden kann [12]. Dabei werden Anfrage und jeweilige Passage gemeinsam verarbeitet, sodass deren Beziehung unmittelbar in die Relevanzbewertung einfließen kann. Ein solches Vorgehen wird als Cross-Encoder-Reranking bezeichnet.

Im Unterschied zu Retrieval-Verfahren, bei denen Dokumentrepräsentationen vorab berechnet und effizient über große Dokumentbestände durchsucht werden können, muss ein Cross-Encoder jedes Query-Dokument-Paar separat verarbeiten. Der höhere Berechnungsaufwand begrenzt seinen Einsatz auf eine zuvor bestimmte Kandidatenmenge. Reranking bildet deshalb typischerweise eine nachgelagerte Stufe der Retrieval-Pipeline.

Abbildung 1 fasst die beschriebenen Komponenten zusammen. Eine Anfrage wird zunächst parallel durch Sparse und Dense Retrieval verarbeitet. Die resultierenden Rankings können mittels RRF fusioniert und die verbleibenden Kandidaten anschließend durch einen Cross-Encoder neu bewertet werden. Die ausgewählten Inhalte bilden schließlich den zusätzlichen Kontext für die Generierung durch das LLM. Die konkrete technische Umsetzung und Konfiguration dieser Komponenten im untersuchten System wird in Kapitel 3 beschrieben.




Figure 1: Schematischer Ablauf einer hybriden RAG-Pipeline mit Reranking.

2.3 Evaluation LLM-basierter Dialogsysteme

Die Bewertung von LLM-basierten Dialogsystemen unterscheidet sich von Aufgaben, für die eine eindeutig definierte Zielausgabe vorliegt. Insbesondere bei offenen Dialogen können mehrere inhaltlich und sprachlich unterschiedliche Antworten eine gestellte Anforderung erfüllen. Für solche Ausgaben kann ein Large Language Model selbst als Evaluators eingesetzt werden. Dieses Verfahren wird als *LLM-as-a-Judge* bezeichnet.

2.3.1 LLM-as-a-Judge

Beim LLM-as-a-Judge wird ein Large Language Model eingesetzt, um die Ausgabe eines zu untersuchenden LLM-Systems anhand vorgegebener Bewertungskriterien zu beurteilen. Zheng et al. untersuchen diesen Ansatz für die Evaluation von Chat-Assistenten und verwenden leistungsfähige LLMs sowohl zur Bewertung einzelner Antworten als auch zum Vergleich verschiedener Antworten [15]. Damit übernimmt das bewertende Modell eine Funktion, die andernfalls beispielsweise durch menschliche Evaluatoren ausgeführt werden müsste.

Der Ansatz ermöglicht insbesondere die Bewertung von Eigenschaften, die sich nicht ausschließlich durch einen Vergleich mit einer festgelegten Referenzantwort bestimmen lassen. Die Bewertung bleibt jedoch vom eingesetzten Judge-Modell und vom Bewertungsverfahren abhängig. Zheng et al. identifizieren unter anderem einen *Position Bias*, bei dem die Position einer Antwort das Urteil beeinflussen kann, einen *Verbosity Bias*, der ausführlichere Antworten begünstigen kann, sowie einen *Self-Enhancement Bias* zu Gunsten von Antworten verwandter Modelle [15]. LLM-as-a-Judge ist daher nicht als objektive Messung zu verstehen, sondern als modellbasierte Evaluationsmethode, deren Ausgestaltung bei der Interpretation der Ergebnisse berücksichtigt werden muss.

2.3.2 Multi-Turn-Evaluation und ConversationalTestCase

Bei einem Dialogsystem hängt die Qualität einer Antwort nicht ausschließlich von der unmittelbar vorhergehenden Eingabe ab. Aussagen, Anforderungen oder Informationen aus früheren Gesprächsschritten können für spätere Antworten weiterhin maßgeblich sein. Eine isolierte Bewertung einzelner Input-Output-Paare kann deshalb Eigenschaften wie die Berücksichtigung des Gesprächskontexts oder ein konsistentes Verhalten über den gesamten Dialog nur eingeschränkt erfassen. DeepEval unterscheidet hierzu zwischen Single-Turn- und Multi-Turn-Evaluation und verwendet für letztere den `ConversationalTestCase` [3].

Ein `ConversationalTestCase` repräsentiert eine vollständige Konversation als Folge von `Turn`-Objekten. Ein `Turn` enthält insbesondere die jeweilige Rolle, beispielsweise `user` oder `assistant`, sowie den Inhalt der Nachricht. Zusätzlich kann ein `Conversational Test Case` Angaben zum Szenario, zum erwarteten Ergebnis, zum verfügbaren Kontext

oder zur vorgesehenen Rolle des Chatbots enthalten [3]. Die Konversation bildet damit die gemeinsame Evaluationsgrundlage für Metriken, deren Bewertung sich über mehrere Interaktionen erstreckt.

Diese Betrachtung ist insbesondere für Tutor-Chatbots erforderlich. Ein einzelner Turn kann für sich betrachtet einer vorgesehenen Tutorstrategie entsprechen, während das System diese Strategie in späteren Gesprächsschritten nicht fortführt. Die Multi-Turn-Evaluation ermöglicht deshalb die Untersuchung, ob gewünschte Eigenschaften über den Gesprächsverlauf hinweg erhalten bleiben.

2.3.3 Conversational G-Eval

Für Anforderungen, für die keine vorgegebene Metrik existiert, stellt DeepEval mit `ConversationalGEval` eine anpassbare LLM-as-a-Judge-Metrik für Multi-Turn-Konversationen bereit [2]. Hierzu wird ein natürlichsprachliches Bewertungskriterium definiert, anhand dessen ein Judge-Modell die im `ConversationalTestCase` enthaltene Konversation beurteilt. Im Gegensatz zu einer auf einzelne Antworten beschränkten Bewertung kann damit das Verhalten über den gesamten Gesprächsverlauf Gegenstand des Bewertungskriteriums sein.

Dadurch können anwendungsspezifische Qualitätsanforderungen operationalisiert werden, für die keine allgemeingültige Metrik vorhanden ist. Im Kontext eines Tutors können solche Kriterien beispielsweise das didaktische Verhalten oder die Einhaltung bestimmter Gesprächsstrategien betreffen. Die konkrete Formulierung dieser Kriterien sowie ihre Verwendung für die Evaluation des in dieser Arbeit untersuchten Tutors werden im Methodikkapitel beschrieben.

2.3.4 Vordefinierte Multi-Turn-Metriken

Neben frei definierbaren Kriterien stellt DeepEval vordefinierte Metriken für wiederkehrende Qualitätsdimensionen von Multi-Turn-Systemen bereit. Für die vorliegende Untersuchung sind insbesondere *Role Adherence*, *Turn Contextual Relevancy* und *Turn Faithfulness* relevant.

Die *Role Adherence* bewertet, in welchem Maß ein Dialogsystem die ihm vorgegebene Rolle über den Gesprächsverlauf hinweg einhält. Hierzu werden die Assistant-Turns unter Berücksichtigung der vorausgehenden Konversation mit der im `ConversationalTestCase` definierten `chatbot_role` verglichen [4]. Die Metrik ermöglicht damit eine Bewertung, ob das gewünschte Rollenverhalten auch über mehrere Gesprächsschritte hinweg beibehalten wird.

Für die Bewertung der RAG-Komponente werden *Turn Contextual Relevancy* und *Turn Faithfulness* herangezogen. *Turn Contextual Relevancy* untersucht, ob der für einen Turn abgerufene Retrieval-Kontext für die jeweilige Nutzereingabe relevant ist [5]. Die

Metrik richtet sich damit auf die Qualität der bereitgestellten Kontextinformationen.

Turn Faithfulness betrachtet dagegen die Beziehung zwischen dem Retrieval-Kontext und der generierten Antwort. Bewertet wird, ob die Aussagen des Assistenten durch die für den jeweiligen Turn bereitgestellten Informationen gestützt werden [6]. Während *Turn Contextual Relevancy* somit die Relevanz des abgerufenen Kontexts bewertet, untersucht *Turn Faithfulness*, ob die Antwort auf diesem Kontext basiert.

Die drei Metriken adressieren damit unterschiedliche Qualitätsdimensionen des Dialogsystems: *Role Adherence* die Einhaltung der vorgesehenen Tutorrolle, *Turn Contextual Relevancy* die Relevanz der abgerufenen Inhalte und *Turn Faithfulness* deren Nutzung bei der Antwortgenerierung. Die konkrete Zuordnung der Metriken zu den Forschungsfragen wird im Methodikkapitel beschrieben.

3 Untersuchungsgegenstand

Die Untersuchung betrachtet sowohl das Tutorverhalten als auch die Bereitstellung des fachlichen Kontexts. RQ1 adressiert den Vergleich unterschiedlicher Systemprompt-Varianten hinsichtlich ihres sokratischen Tutorverhaltens, während RQ2 die untersuchten RAG-Konfigurationen gegenüberstellt. Die Grundlage beider Untersuchungen ist die im Folgenden dargestellte RAG-Pipeline.

3.1 Die RAG-Pipeline

Als Untersuchungsgegenstand dient eine Open-WebUI-kompatible RAG-Pipeline, die OpenAI-kompatible Chat-Completion-Anfragen verarbeitet und Qdrant als Vektordatenbank für das Retrieval verwendet. Die Pipeline unterstützt Dense, Sparse und Hybrid Retrieval sowie Reciprocal Rank Fusion (RRF) und optionales Cross-Encoder-Reranking. Darüber hinaus können Kontextinformationen aus Moodle in die Verarbeitung einbezogen werden.

Der grundsätzliche Ablauf ist in Abbildung 2 dargestellt. Nach Eingang einer Nutzeranfrage werden zunächst die Request-Parameter und die aktuelle Frage bestimmt. Abhängig von der gewählten Retrieval-Konfiguration wird die Anfrage anschließend über Dense Retrieval, Sparse Retrieval oder eine Kombination beider Verfahren verarbeitet. Im hybriden Modus werden Dense- und Sparse-Repräsentationen parallel erzeugt. Die resultierenden Rankings werden mittels RRF zusammengeführt. Dabei wird, sofern verfügbar, die serverseitige Fusion durch Qdrant verwendet; andernfalls erfolgt die Fusion lokal innerhalb der Pipeline.

Die resultierenden Kandidaten werden zusammengeführt und gegebenenfalls dedupliziert. Optional kann anschließend ein Cross-Encoder die Kandidaten erneut bewerten und neu sortieren. Nach dem Retrieval beziehungsweise Reranking werden ein Score-Threshold sowie ein finales Trefferlimit angewendet. Die verbleibenden Chunks bilden die Grundlage für den RAG-Kontext. Dabei begrenzt ein Kontextbudget die Menge der tatsächlich an das Sprachmodell übergebenen Inhalte, sodass nicht zwingend jeder finale Retrieval-Treffer Bestandteil des LLM-Kontexts ist.

Für die Generierung wird der Prompt aus mehreren Bestandteilen zusammengesetzt. Im RAG-Pfad werden zunächst der aktive Systemprompt, anschließend ein optionaler Moodle-Kontext und der aus dem Retrieval erzeugte RAG-Kontext eingefügt. Darauf folgen die bereinigte bisherige Gesprächshistorie und die aktuelle Nutzerfrage. Die Pipeline ermöglicht damit, sowohl retrieved Informationen als auch den bisherigen Gesprächsverlauf bei der Generierung einer Tutorantwort zu berücksichtigen.

Version 1.7.0 stellt zusätzlich einen Verbose-Modus für Non-Streaming-Anfragen bereit. Dieser gibt unter anderem Informationen über die Vektorisierung, die Retrieval- und Fusionsergebnisse, das Reranking, die tatsächlich an das LLM übergebenen Nachrichten sowie die rohe und finale Modellantwort strukturiert aus. Der Verbose-Modus greift dabei




Figure 2: Architektur und Verarbeitungsschritte der untersuchten RAG-Pipeline in Version 1.7.0.

auf bereits während der regulären Verarbeitung erzeugte Daten zurück und führt keine zusätzlichen Retrieval-, Embedding-, Reranking- oder LLM-Aufrufe aus. Dadurch können die einzelnen Verarbeitungsschritte für die spätere Evaluation nachvollzogen werden. Die für die Untersuchung variierten Retrieval- und Reranking-Konfigurationen werden in Abschnitt ?? beschrieben.

3.2 Die Prompt-Varianten für RQ1

Zur Beantwortung von RQ1 werden vier Varianten des Systemprompts miteinander verglichen. Sie unterscheiden sich hinsichtlich des Umfangs der Instruktionen, der Strukturierung des sokratischen Dialogs und der Anpassung an den konkreten Einsatz im Elektrotechniklabor. Dadurch soll untersucht werden, welchen Einfluss die Ausgestaltung des Systemprompts auf das resultierende Tutorverhalten hat. Die vollständigen Wortlaute der verwendeten Prompts sind in Anhang A dokumentiert.

Die *Baseline ohne Systemprompt* enthält keine zusätzliche Instruktion zur Rolle oder zum Verhalten des Modells. Sie dient als Referenz, um zu untersuchen, welches Tutorverhalten das Sprachmodell ohne explizite Vorgaben zum sokratischen Vorgehen zeigt.

Der *Minimale sokratische Prompt* definiert das Modell als sokratischen Tutor für Elektrotechnik. Vorgegeben wird lediglich, Gegenfragen anstelle direkter Antworten zu stellen und Studierende durch Fragen zur eigenständigen Erkenntnis zu führen. Weitere Regeln zum Ablauf des Gesprächs oder zum Umgang mit bestimmten Situationen werden nicht festgelegt.

Der *Strukturierte sokratische Prompt* konkretisiert den Ablauf des sokratischen Dialogs. Ausgangspunkt soll eine konkrete Erfahrung der studierenden Person sein, aus der schrittweise Begriffe, Urteile sowie zugrunde liegende Überzeugungen und Prinzipien herausgearbeitet werden. Der Tutor soll sich dabei weitgehend aus der direkten fachlichen Problemlösung heraushalten, Gegenperspektiven einbringen und die studierende Person durch Fragen zum eigenständigen Weiterdenken anregen. Zusätzlich enthält der Prompt die Vorgabe, die Lösung einer Quizfrage nicht direkt oder indirekt preiszugeben.

Der *Domänenspezifische In-Lab-Tutorprompt* überträgt das sokratische Tutorverhalten auf Situationen während eines Elektrotechniklabors. Neben der Förderung eigenständigen Denkens enthält er Vorgaben zur Berücksichtigung des Vorwissens, zur Entwicklung und Prüfung eigener Fehlerhypothesen sowie zur Begrenzung der Informationsmenge und der Anzahl der Impulse pro Antwort. Darüber hinaus definiert der Prompt Eskalationsregeln für sicherheitsrelevante oder durch die Laborbetreuung zu klärende Situationen.

Tabelle 1 fasst die wesentlichen Unterschiede der vier Varianten zusammen.

Die vier Varianten bilden damit unterschiedliche Grade der Steuerung durch den Systemprompt ab. Während die Baseline vollständig auf eine sokratische Instruktion

Table 1: Für RQ1 untersuchte Prompt-Varianten.

ID	Variante	Umfang	Schwerpunkt
A	Baseline ohne Systemprompt	keiner	Keine explizite Vorgabe eines sokratischen Tutorverhaltens.
B	Minimaler sokratischer Prompt	gering	Definition der Tutorrolle sowie Vorgabe von Gegenfragen und Förderung eigenständiger Erkenntnis.
C	Strukturierter sokratischer Prompt	hoch	Vorgegebener sokratischer Gesprächsablauf und Vermeidung direkter Lösungsweitergabe.
D	Domänenspezifischer In-Lab-Tutorprompt	hoch	Anpassung des Tutorverhaltens an das Elektrotechniklabor mit Hypothesenbildung, begrenzten Impulsen und Eskalationsregeln.

verzichtet und der minimale Prompt lediglich das Grundprinzip vorgibt, operationalisieren die beiden umfangreicheren Varianten das gewünschte Tutorverhalten stärker. Der strukturierte sokratische Prompt fokussiert dabei den Ablauf des sokratischen Dialogs, während der domänenspezifische In-Lab-Tutorprompt zusätzlich Anforderungen des konkreten Laborkontexts berücksichtigt. Die methodische Durchführung des Vergleichs wird in Kapitel 4 beschrieben.

3.3 RAG-Konfigurationen für RQ2

Zur Beantwortung von RQ2 werden unterschiedliche Konfigurationen der in Abschnitt 3.1 beschriebenen RAG-Pipeline untersucht. Die Varianten unterscheiden sich hinsichtlich der verwendeten Wissensbasis, des Retrieval-Verfahrens und des Einsatzes eines Cross-Encoder-Rerankings. Dadurch kann untersucht werden, welchen Einfluss diese Komponenten auf die Qualität des bereitgestellten Retrieval-Kontexts und der darauf basierenden Antworten haben.

Als Wissensbasis werden eine Collection mit Vorlesungsinhalten, eine Collection mit Laborinhalten sowie die Kombination beider Collections betrachtet. Für das Retrieval kommen Dense, Sparse und Hybrid Retrieval zum Einsatz. Beim hybriden Verfahren werden Dense und Sparse Retrieval kombiniert und die resultierenden Ranglisten mittels Reciprocal Rank Fusion zusammengeführt. In ausgewählten Konfigurationen wird anschließend zusätzlich das in Abschnitt 3.1 beschriebene Cross-Encoder-Reranking angewendet.

Neben den RAG-Konfigurationen wird eine *LLM-only*-Variante untersucht. Bei dieser wird keine Collection ausgewählt, sodass Retrieval und Reranking vollständig übersprungen werden. Sie dient als Referenz für die Antwortgenerierung ohne zusätzlich bereitgestellten Retrieval-Kontext.

Tabelle 2 zeigt die für RQ2 untersuchten Konfigurationen.

Table 2: Für RQ2 untersuchte RAG-Konfigurationen.

Variante	Wissensbasis	Retrieval	Reranking
Beide – Hybrid	Vorlesung + Labor	Hybrid	Nein
Beide – Sparse	Vorlesung + Labor	Sparse	Nein
Beide – Hybrid + Reranking	Vorlesung + Labor	Hybrid	Ja
Vorlesung – Hybrid + Reranking	Vorlesung	Hybrid	Ja
Labor – Hybrid + Reranking	Labor	Hybrid	Ja
Beide – Dense	Vorlesung + Labor	Dense	Nein
Labor – Dense	Labor	Dense	Nein
Vorlesung – Dense	Vorlesung	Dense	Nein
LLM-only	keine	kein Retrieval	Nein

Die Auswahl der Varianten ermöglicht mehrere Vergleichsperspektiven. Durch die Dense-, Sparse- und Hybrid-Konfigurationen werden unterschiedliche Retrieval-Ansätze gegenübergestellt. Die Varianten mit beiden Collections und mit getrennten Vorlesungs- beziehungsweise Laborinhalten erlauben zusätzlich eine Untersuchung des Einflusses der zugrunde liegenden Wissensbasis. Der Vergleich der hybriden Varianten mit und ohne Reranking dient schließlich dazu, den zusätzlichen Einfluss des Cross-Encoder-Rerankings zu betrachten. Die konkrete Durchführung der Evaluation und die hierfür verwendeten Metriken werden in Kapitel 4 beschrieben. Aufgrund des hohen Tokenaufwands und der damit verbundenen Kosten des OpenAI-Zugangs konnte die Evaluation nicht für alle neun vorgesehenen RAG-Konfigurationen vollständig durchgeführt werden. Versuche, die verbleibenden Konfigurationen über die lokale Infrastruktur der Hochschule zu evaluieren, erwiesen sich aufgrund sehr langer Laufzeiten und erreichter Systemgrenzen ebenfalls als nicht praktikabel, sodass nur die Varianten `beide_sparse`, `beide_dense`, `labor_dense`, `vorlesung_dense` und `llm_only` ausgewertet wurden.

4 Methodik

Gegenstand der vorliegenden Untersuchung ist die Evaluation eines sokratischen KI-Tutors, der auf einer Retrieval-Augmented-Generation-Pipeline (RAG) aufsetzt. Ziel ist es, das Zusammenspiel von Prompting und Retrieval-Konfiguration systematisch zu bewerten. Die Untersuchung folgt einem explorativen, experimentellen Evaluationsdesign. Das konkrete Vorgehen zur getrennten Beantwortung von RQ1 und RQ2 wird im folgenden Abschnitt beschrieben.

4.1 Untersuchungsdesign

Die Evaluation ist als automatisierte, mehrstufige Dialogbewertung angelegt. Für jedes Testszenario wird ein Multi-Turn-Gespräch zwischen einer simulierten studierenden Person und dem RAG-gestützten Tutor erzeugt und anschließend anhand eines definierten Metrik-Sets bewertet. Die Wahl eines simulationsbasierten Multi-Turn-Designs ergibt sich unmittelbar aus dem Untersuchungsgegenstand: Da sokratisches Tutoring ein dialogisches, über mehrere Gesprächsrunden verlaufendes Vorgehen ist, lässt es sich nicht anhand einzelner Frage-Antwort-Paare, sondern nur im Verlauf eines Gesprächs angemessen beurteilen (vgl. Abschnitt 2.1).

Zur klaren Trennung der Forschungsfragen wurden zwei separate Evaluationslinien umgesetzt. In der ersten Linie (RQ1) wird bei konstant gehaltener RAG-Konfiguration der System-Prompt variiert. Bewertet wird die sokratische Qualität des Gesprächsverlaufs. In der zweiten Linie (RQ2) wird bei konstant gehaltenem Prompt die RAG-Konfiguration variiert und die *Retrieval-Qualität* bewertet. Durch die Beschränkung auf jeweils einen variierten Faktor je Linie können die beobachteten Effekte den Prompts bzw. den Konfigurationen zugeordnet werden.

4.2 Untersuchungsgegenstand und Datengrundlage

Das zu evaluierende System (System under Test) ist die in Abschnitt 2.2 beschriebene RAG-Pipeline, die intern das Modell `gemma-4-26B` als generierendes Sprachmodell nutzt. Der fachliche Wissenskorpus liegt in zwei Qdrant-Collections vor, die Vorlesungs- bzw. Labormaterial des Fachgebiets Elektronik der Hochschule enthalten.

Die Datengrundlage der Evaluation bilden nicht vorab gesammelte Dialoge, sondern synthetisch erzeugte Gespräche. Grundlage jedes Gesprächs ist ein Testszenario, das sich aus der Kombination von Themengebiet, Kompetenzniveau der studierenden Person (Anfänger bzw. Fortgeschritten) und einem charakteristischen Studierenden-Verhalten (etwa kooperativ, die Lösung einfordernd oder inhaltlich selbstsicher-fehlerhaft) zusammensetzt 3. Insgesamt ergeben sich daraus mehrere Szenarien je Auswertungslinie. Jedes Szenario wird als *Golden* modelliert, das die Ausgangssituation, eine Beschreibung der zu

simulierenden Persona sowie eine feste Initialfrage enthält. Die Initialfrage wird bewusst wortgleich vorgegeben und nicht generiert, um über alle Prompts und Konfigurationen hinweg denselben Gesprächseinstieg und damit die Vergleichbarkeit der Läufe sicherzustellen. Die daran anschließenden Folgefragen werden hingegen dynamisch simuliert.

Table 3: Dimensionen der Testszenarien. Die Kombination aus Themengebiet, Kompetenzniveau und Studierenden-Verhalten ergibt die simulierten Gespräche.

Dimension	Ausprägungen
Themengebiet	Sperrspannung/Durchbruch der Z-Diode; Spannungsstabilisierung mit Z-Diode; Ohmsches Gesetz und Maschenregel
Kompetenzniveau	Anfänger, Fortgeschritten
Studierenden-Verhalten	kooperativ; gibt schnell auf; fordert die Lösung ein; äußert eine Vermutung; selbstsicher, aber inhaltlich falsch

4.3 Evaluationsarchitektur

Da der Untersuchungsgegenstand ein Dialog ist, sind neben dem zu bewertenden System zwei weitere Rollen erforderlich. Die Architektur umfasst somit drei klar getrennte Modelle. Der Tutor ist die RAG-Pipeline gemma-4-26B und beantwortet jeden Gesprächszug. Der Studenten-Simulator übernimmt die Rolle der studierenden Person: Ausgehend von der im Golden festgelegten, wortgleichen Initialfrage erzeugt er auf Basis von Szenario, Persona und der jeweils vorangegangenen Tutor-Antwort dynamisch die weiteren Folgefragen des Gesprächs. Ohne diese Rolle würde kein Dialog entstehen, sondern lediglich ein einzelnes Frage-Antwort-Paar. Als Simulator wird das Modell **gpt-4o-mini** eingesetzt und der Judge bewertet den fertigen Dialog. Hierfür wird mit gpt-4.1 bewusst ein vom System unter Test verschiedenes Modell gewählt, um einen Selbstbewertungs-Bias zu vermeiden, bei dem ein Modell anteilig seine eigenen Ausgaben bewertet 2.3. Simulator und Judge laufen auf getrennten Endpunkten.

4.4 Verwendete Methoden und Werkzeuge

Die technische Umsetzung erfolgt in Python unter Verwendung des Evaluations-Frameworks DeepEval. Die Multi-Turn-Gespräche werden mit dem ConversationSimulator des Frameworks erzeugt. Ausgehend von der festen Initialfrage generiert der Simulator über eine festgelegte Anzahl von Runden fortlaufend Studierenden-Nachrichten, die über eine Callback-Schnittstelle an die RAG-Pipeline gesendet werden. Die Antwort bildet jeweils den näch-




Figure 3: Ablauf der Dialog-Simulation: Aus einem Golden erzeugt der Conversation Simulator (in der Rolle der studierenden Person) fortlaufend Fragen an den RAG-Tutor. Der resultierende Multi-Turn-Dialog wird anschließend vom Judge bewertet.

sten Assistant-Turn. Die Zuordnung von Antworten zu Metriken erfolgt anschließend über ConversationalTestCase-Objekte des Frameworks.

Für die kontextbezogenen Metriken wird der tatsächlich abgerufene Retrieval-Kontext benötigt. Dieser wird über den Verbose-Modus der RAG-Pipeline gewonnen, der bei deaktiviertem Streaming eine strukturierte Antwort liefert, aus der die finalen Retrieval-Chunks samt Text extrahiert und den jeweiligen Antworten zugeordnet werden. Zwei Aufbereitungsschritte werden dabei transparent gemacht: Zum einen wird der abgerufene Kontext bereits beim Einlesen der RAG-Antwort auf eine handhabbare Länge begrenzt (maximal vier Chunks à 2000 Zeichen), um ein Überschreiten des Kontextfensters des Judge zu vermeiden. Diese Begrenzung betrifft die gespeicherten Gespräche direkt, da sie vor deren Speicherung angewendet wird. Zum anderen wird die mathematische Notation (LaTeX) unmittelbar vor der Bewertung für eine separate Kopie normalisiert, da sie andernfalls die strukturierte Ausgabe des Judge stört. Hiervon bleiben die gespeicherten Gespräche unverändert.

4.5 Bewertungskriterien

Die Bewertung ist entlang der beiden Forschungsfragen unterschiedlich ausgestaltet.

4.5.1 Sokratische Qualität (RQ1)

Sokratisches Tutoring ist ein didaktik-spezifisches Konstrukt, für das im verwendeten Framework keine vorgefertigten Metriken existieren. Es wird daher über eigene, mittels G-Eval operationalisierte Kriterien bewertet, die jeweils über explizite Bewertungsschritte und eine dreistufige Bewertungsskala (Rubric) verankert sind. Verwendet werden die Kriterien *Lösung nicht verraten*, *Sokratische Rückfragen*, *Schrittweise Lernprogression*, *Niveau-Anpassung*, *Fachliche Korrektheit*, *Verständnisförderung/Transfer* sowie *Respektvolle Kommunikation*. Ergänzend wird die im Framework enthaltene Metrik zur Rollentreue (*RoleAdherence*) als Gegenprüfung herangezogen, da sie die Treue zur im Testfall

hinterlegten sokratischen Rollendefinition misst und damit als einzige native Metrik das Konstrukt indirekt berührt⁴.

Bewusst nicht verwendet werden Metriken, die dem sokratischen Ziel widersprechen oder es verfehlen. Dies betrifft insbesondere eine Metrik zur direkten Zielerreichung, die die unmittelbare Beantwortung der Fachfrage bewertet und damit dem Prinzip, die Lösung gerade nicht vorwegzunehmen, entgegensteht, sowie eine generische Turn-Relevanz-Metrik, die legitimes sokratisches Umlenken als weniger relevant einstufen kann.

Zur Beantwortung von RQ1 werden die vier in Abschnitt 3.2 eingeführten Prompt-Varianten A–D verglichen, die in den Rohdaten den Dateien `no_Prompt` (A), `minimaler_sokrat` (B), `system_prompt` (C) und `stock_prompt` (D) entsprechen. Der vollständige Wortlaut der Prompts ist im Anhang dokumentiert.

Table 4: Bewertungskriterien der sokratischen Qualität (RQ1) mit ihrer literaturgestützten Fundierung. Sechs Kriterien werden als eigene ConversationalGEval-Metriken operationalisiert, die Rollentreue (RoleAdherence) wird als native Metrik ergänzend als Gegenprüfung herangezogen.

Kriterium	Gemessenes Konstrukt
Lösung nicht verraten	Führt zur eigenen Erkenntnis, statt die Lösung zu nennen; lässt eigene Denkarbeit.
Sokratische Rückfragen	Zielgerichtete, offene Fragen – keine Fragen „um der Frage willen“.
Schrittweise Lernprogression	Neues Wissen in kleinen Schritten auf Vorwissen aufbauend.
Niveau-Anpassung	Diagnostiziert das Niveau und unterrichtet daran angepasst.
Fachliche Korrektheit	Real korrekte Fachinhalte; keine erfundenen Formeln/Werte.
Verständnisförderung / Transfer	Betont wichtige Lernpunkte; fördert Verständnis statt Reproduktion.
Respektvolle Kommunikation	Ziel ist Lehren, nicht Bloßstellen; keine Beschämung.
RoleAdherence (nativ)	Gegenprüfung der Treue zur sokratischen Rollendefinition.

4.5.2 Retrieval-Qualität (RQ2)

Für den Vergleich der RAG-Konfigurationen werden die nativen Metriken *TurnContextualRelevancy* (Passung des abgerufenen Kontexts zur Frage) und *TurnFaithfulness* (Deckung der Antwort durch den abgerufenen Kontext) verwendet. Beide beziehen den zuvor extrahierten Retrieval-Kontext ein und eignen sich damit zur Unterscheidung von

Retrieval-Konfigurationen.

Table 5: Bewertungskriterien der Retrieval-Qualität (RQ2). Die beiden Metriken sind native DeepEval-Metriken und beziehen den tatsächlich abgerufenen `retrieval_context` ein. Die Abdeckung und die effektive Retrieval-Güte werden daraus abgeleitet.

Kennzahl		Herkunft	Gemessenes Konstrukt
TurnContextualRelevancy		nativ	Passung des abgerufenen Kontexts zur jeweiligen Frage.
TurnFaithfulness		nativ	Deckung der Antwort durch den abgerufenen Kontext (Grounding).
Retrieval-Abdeckung		abgeleitet	Anteil der Antworten mit tatsächlich abgerufenem Kontext (aus den Konversationsdaten).
Effektive Güte	Retrieval-	abgeleitet	Produkt aus Abdeckung und Kontext-Relevanz. Berücksichtigt, wie oft <i>und</i> wie gut Kontext abgerufen wird.

4.6 Durchführung

Die Durchführung erfolgt zweiphasig und je Prompt-Version bzw. Konfiguration getrennt: Zunächst werden alle Gespräche simuliert, anschließend werden sie bewertet. Diese Trennung erlaubt es, die netz- und laufzeitintensive Simulation gegen den RAG-Endpunkt einmalig durchzuführen und die Judge-Bewertung unabhängig davon zu wiederholen. Zur Sicherstellung der Reproduzierbarkeit werden die simulierten Gespräche je Konversation atomar zwischengespeichert. Über eine deterministische Konversations-ID wird ein unterbrochener Lauf beim Neustart fortgesetzt, ohne bereits erzeugte Gespräche neu zu berechnen. Die Bewertungsergebnisse werden fortlaufend je Metrik protokolliert und ebenfalls fortsetzbar geschrieben.

Für RQ1 werden vier Prompt-Varianten bei einer festen RAG-Konfiguration ausgewertet. Für RQ2 wird ein fester sokratischer Prompt mit einer Matrix aus neun RAG-Konfigurationen kombiniert, die sich in den einbezogenen Collections, im Retrieval-Modus (dense, sparse, hybrid) und im Einsatz des Cross-Encoder-Rerankings unterscheiden und zusätzlich eine reine LLM-Konfiguration ohne Retrieval als Referenz umfassen. Zur Steuerung der Endpunkt-Auslastung wird ein gemeinsamer Rate-Limiter eingesetzt. Transiente Fehler (etwa Rate-Limits oder Timeouts) werden mit ansteigender Wartezeit wiederholt, deterministische Fehler hingegen unmittelbar protokolliert.

Die Auswertung erfolgt anschließend automatisiert: Aus den protokollierten Rohdaten werden je Auswertungslinie die beschriebenen Kennzahlen berechnet und zur weiteren Analyse mit pandas (Aggregation, Pivot-Tabellen) und matplotlib (Balkendiagramme, Boxplots, Heatmaps) in Jupyter-Notebooks aufbereitet.

4.7 Gütekriterien und methodische Einschränkungen

Sämtliche Bewertungen sind Urteile eines LLM-Judge und damit modellabhängig. Ergebnisse verschiedener Judge-Modelle sind nicht unmittelbar vergleichbar. Die selbst definierten G-Eval-Kriterien sind projektspezifisch und wurden durch eine manuelle Nachbewertung einer Stichprobe abgesichert. Da ein Teil der Antworten ohne abgerufenen Kontext erzeugt wird, sind die kontextbezogenen Metriken nur eingeschränkt aussagekräftig. Aufgrund der begrenzten Anzahl an Szenarien je Konfiguration sind die Ergebnisse als explorativ zu verstehen.

4.8 Projekt-Setup

Die vollständige technische Umsetzung – Installation, Konfiguration der Endpunkte und Modelle, Ausführung von Simulation und Bewertung sowie Erweiterung um neue Prompt-Varianten, RAG-Konfigurationen oder Bewertungskriterien – ist im Projektrepositorium in einer begleitenden README dokumentiert. Diese ist bewusst auf Nachvollziehbarkeit und Wiederverwendbarkeit ausgelegt, sodass die Evaluation auch nach Abschluss dieser Arbeit reproduziert oder für andere Anwendungsfälle angepasst werden kann, ohne den Quellcode im Detail nachvollziehen zu müssen.

5 Ergebnisse

Als Ergebnis liegen die Simulierten Konversationen beider Forschungsfragen, sowie die vollumfänglich evaluierten Konversationen der ersten Forschungsfrage (RQ1) vor. Die Evaluierung der zweiten Forschungsfrage (RQ2) ist aufgrund der langen Berechnungszeiten der RAG-Metriken noch nicht abgeschlossen. Es wurden 5 von 9 RAG-Konfigurationen vollständig evaluiert. Die vollständigen Ergebnisse der RQ2 werden daher in einem späteren Schritt nachgereicht.

5.1 RQ1 – Vergleich der Prompt-Varianten

Verglichen werden die vier eingeführten Prompt-Varianten *A* (Baseline ohne Systemprompt), *B* (Minimaler sokratischer Prompt), *C* (Strukturierter sokratischer Prompt) und *D* (Domänenspezifischer In-Lab-Tutorprompt) bei konstant gehaltener RAG-Konfiguration. Alle Metriken sind auf den Wertebereich 0 bis 1 normiert. Als Bestehensgrenze der Einzelmetriken gilt der Schwellenwert 0,7. Die Pass-Rate bezeichnet den Anteil der Gespräche mit einem Score $\geq 0,7$. Neben Mittelwerten werden, wo dies für die Beurteilung der Ergebnisstabilität relevant ist, auch Streuungsmaße und die Verteilung über Scorebänder berichtet. Die Bewertung erfolgt über die G-Eval-Kriterien der sokratischen Qualität sowie die native Metrik Role Adherence.

5.1.1 Ergebnisse je Kriterium

Tabelle 6 stellt den Mittelwert ($\emptyset$) und die Pass-Rate (PR, in %) je Kriterium und Prompt-Variante gegenüber. Abbildung 4 visualisiert die Mittelwerte als Balkendiagramm und Abbildung 5 verdichtet sie als Heatmap.

Table 6: Mittelwert ($\emptyset$) und Pass-Rate (PR, in %) je Kriterium und Prompt-Variante. (Legende: A = Baseline ohne Systemprompt, B = Minimaler sokratischer Prompt, C = Strukturierter sokratischer Prompt, D = Domänenspezifischer In-Lab-Tutorprompt)

Kriterium	C	D	B	A
Lösung nicht verraten	0,94 (94 %)	0,95 (97 %)	0,83 (77 %)	0,34 (13 %)
Sokratische Rückfragen	0,97 (100 %)	0,95 (97 %)	0,92 (93 %)	0,39 (30 %)
Schrittweise Lernprogression	0,91 (94 %)	0,91 (90 %)	0,90 (83 %)	0,98 (100 %)
Niveau-Anpassung	0,84 (78 %)	0,89 (80 %)	0,89 (80 %)	0,97 (100 %)
Fachliche Korrektheit	0,97 (100 %)	0,98 (100 %)	0,99 (100 %)	1,00 (100 %)
Verständnisförderung / Transfer	0,98 (100 %)	0,96 (100 %)	0,96 (100 %)	0,96 (97 %)
Respektvolle Kommunikation	0,94 (94 %)	0,95 (93 %)	0,94 (97 %)	1,00 (100 %)
Role Adherence (nativ)	0,94 (89 %)	0,92 (90 %)	0,93 (100 %)	0,16 (7 %)

Bereits auf Ebene der Einzelkriterien zeigt sich ein deutliches Muster. Bei den allgemeinen, sachlichen Qualitätskriterien: Fachliche Korrektheit, Schrittweise Lernprogression




Figure 4: Mittelwert je Kriterium und Prompt-Variante. Die gestrichelte Linie markiert den Schwellenwert 0,7. (Legende: A = Baseline ohne Systemprompt, B = Minimaler sokratischer Prompt, C = Strukturierter sokratischer Prompt, D = Domänenspezifischer In-Lab-Tutorprompt)




Figure 5: Mittelwerte je Kriterium und Prompt-Variante als Heatmap.

sion, Niveau-Anpassung und Respektvolle Kommunikation liegen alle vier Varianten dicht beieinander auf einem sehr hohen Niveau.

Bei den sokratisch-spezifischen Kriterien „Lösung nicht verraten“, „Sokratische Rückfragen“ und Role Adherence trennen sich die Varianten hingegen deutlich: *Baseline ohne Systemprompt* fällt hier auf Werte von 0,34, 0,39 und 0,16 ab, während alle drei instruierten Varianten Werte zwischen 0,83 und 0,97 erreichen. Eine Einordnung dieses Musters erfolgt in Abschnitt 6.

Zusätzlich zeigt sich ein gegenläufiger Zusammenhang zwischen Lösungszurückhaltung und Niveau-Anpassung: Die Variante mit dem höchsten Wert bei „Lösung nicht verraten“ (*Strukturierter sokratischer Prompt*, 0,94) erzielt unter den drei instruierten Varianten gleichzeitig den niedrigsten Wert bei der Niveau-Anpassung (0,84). Dieser Zusammenhang wird in Abschnitt 6 vertieft eingeordnet.

5.1.2 Ergebnisstabilität und Streuung

Tabelle 7 zeigt die Standardabweichung je Kriterium und Prompt-Variante.

Table 7: Standardabweichung je Kriterium und Prompt-Variante. Niedrigere Werte bedeuten konsistentere Ergebnisse. (Legende: A = Baseline ohne Systemprompt, B = Minimaler sokratischer Prompt, C = Strukturierter sokratischer Prompt, D = Domänenspezifischer In-Lab-Tutorprompt)

Kriterium	C	D	B	A
Lösung nicht verraten	0,17	0,14	0,29	0,25
Sokratische Rückfragen	0,06	0,09	0,14	0,40
Schrittweise Lernprogression	0,17	0,16	0,15	0,05
Niveau-Anpassung	0,26	0,21	0,20	0,05
Fachliche Korrektheit	0,07	0,06	0,03	0,02
Verständnisförderung / Transfer	0,04	0,06	0,06	0,09
Respektvolle Kommunikation	0,12	0,13	0,13	0,00
Role Adherence (nativ)	0,16	0,16	0,11	0,23

Besonders ausgeprägt ist dieser Effekt bei den kritischen Kriterien: Der *Minimaler sokratischer Prompt* weist bei „Lösung nicht verraten“ (0,29) und „Sokratische Rückfragen“ (0,14) die höchste Streuung aller vier Prompt-Varianten auf, während die ausführlicheren Prompts (*Strukturierter sokratischer Prompt* und *Domänenspezifischer In-Lab-Tutorprompt*) in denselben Kriterien deutlich konsistenter abschneiden (0,06–0,17). Mögliche Ursachen für diesen Unterschied werden in Abschnitt 6 diskutiert.

5.1.3 Ergebnisse je Prompt-Variante

Strukturierter sokratischer Prompt. Höchster Wert bei Sokratische Rückfragen (0,97; Streuung 0,06) und Verständnisförderung (0,98) unter allen vier Prompt-Varianten.

Niedrigster Wert innerhalb dieser Variante ist die Niveau-Anpassung (0,84; vgl. Abschnitt 6.1).

Domänenspezifischer In-Lab-Tutorprompt. 0,95 bei „Lösung nicht verraten“ (Streuung 0,14), 0,89 bei der Niveau-Anpassung welcher der höchste Wert unter den drei instruierten Prompt-Varianten ist und 0,95 bei Sokratische Rückfragen.

Minimaler sokratischer Prompt. Höchste Werte aller Prompt-Varianten bei Fachlicher Korrektheit (0,99) und Verständnisförderung (0,96). Bei „Lösung nicht verraten“ liegt die Variante mit 0,83 (Streuung 0,29) am niedrigsten unter den drei instruierten Varianten (vgl. Abschnitt 6.1). **Baseline ohne Systemprompt.** Deutlicher Abfall bei den sokratisch-spezifischen Kriterien (Role Adherence 0,16; Sokratische Rückfragen 0,39), gleichzeitig Maximalwerte bei Fachlicher Korrektheit (1,00) und Respektvoller Kommunikation (1,00). Eine Einordnung dieses Musters erfolgt in Abschnitt 6.1.

5.2 Querschnitt: Verhalten, Thema und Niveau

5.2.1 Verteilung der Einzelscores




Figure 6: Verteilung der Einzelscores je Kriterium, über alle Prompt-Varianten hinweg.

Abbildung 6 zeigt die Verteilung der Einzelscores je Kriterium getrennt für die vier Prompt-Varianten und ergänzt damit die in Tabelle 6 und Tabelle 7 berichteten Mittel-

werte und Standardabweichungen um die vollständige Verteilungsform.

Bei den allgemeinen Qualitätskriterien: Fachliche Korrektheit, Verständnisförderung/Transfer und Respektvolle Kommunikation, liegen die Verteilungen bei allen vier Varianten eng konzentriert oberhalb der 0,7-Schwelle, mit vereinzelt Ausreißern nach unten.

Bei den sokratisch-spezifischen Kriterien „Lösung nicht verraten“, „Sokratische Rückfragen“ und Role Adherence unterscheidet sich das Bild deutlich zwischen den Varianten: Für *Minimaler sokratischer Prompt*, *Strukturierter sokratischer Prompt* und *Domänen-spezifischer In-Lab-Tutorprompt* liegen die Boxen für diese drei Kriterien überwiegend oberhalb der 0,7-Schwelle, mit einzelnen niedrigen Ausreißern. Für *Baseline ohne Systemprompt* hingegen erstrecken sich Box und Whisker bei genau diesen drei Kriterien über nahezu den gesamten Wertebereich von 0 bis 1, bei einem Median unterhalb der 0,7-Schwelle.

Bei der Niveau-Anpassung zeigt *Strukturierter sokratischer Prompt* mehrere Ausreißer unterhalb von 0,5 (vgl. Tabelle 8), während die Box selbst oberhalb der 0,7-Schwelle liegt – die Verteilung ist hier also überwiegend hoch, mit einer kleinen Gruppe deutlich abweichender Einzelfälle. Eine inhaltliche Einordnung der beschriebenen Muster erfolgt in Abschnitt 6.1. Tabelle 8 zeigt für *Strukturierter sokratischer Prompt* die Verteilung der Einzelscores je Kriterium über drei Score-Bänder. In sechs der acht Kriterien liegen alle Gespräche im obersten Band ($\geq 0,7$); die Niveau-Anpassung ist die einzige Metrik mit einer nennenswerten Zahl schwacher Fälle.

Table 8: Verteilung der Einzelscores je Kriterium für Strukturierter sokratischer Prompt: Anzahl Gespräche mit Score $< 0,5$ / $0,5-0,7$ / $\geq 0,7$.

Kriterium	$< 0,5$	$0,5-0,7$	$\geq 0,7$
Sokratische Rückfragen	0	0	18
Lösung nicht verraten	0	1	17
Schrittweise Lernprogression	0	1	17
Niveau-Anpassung	4	1	13
Fachliche Korrektheit	0	0	18
Respektvolle Kommunikation	0	0	18
Verständnisförderung / Transfer	0	0	18
Role Adherence	0	0	18

5.2.2 Ergebnisse nach Studentenverhalten

Tabelle 9 zeigt die über alle acht Kriterien gemittelte Gesamtstärke je Verhalten und Prompt-Variante.

Über alle Varianten hinweg ist das Verhalten „fordert die Lösung“ das mit Abstand schwierigste. Alle übrigen Verhaltenstypen liegen für die instruierten Varianten nahe dem Maximum. Für *Baseline ohne Systemprompt* liegt die Gesamtstärke hingegen über alle Verhaltensweisen hinweg niedriger (0,63–0,79). Eine Einordnung erfolgt in Abschnitt 6.

Table 9: Über alle acht Kriterien gemittelte Gesamtstärke je Studierenden-Verhalten und Prompt-Variante.

Verhalten	C	D	B	A
fordert die Lösung	0,80	0,79	0,74	0,63
gibt schnell auf	0,97	0,94	0,90	0,77
kooperativ	0,99	0,96	1,00	0,79
selbstsicher, falsch	0,99	0,99	0,99	0,79
äußert eine Vermutung	1,00	0,98	0,98	0,68

5.2.3 Fallbeispiele zu den Unter-Schwellen-Werten

Um zu illustrieren, wodurch Werte unter 0,7 konkret entstehen, wurden Einzelbewertungen mit einem Score unter 0,7 mit der jeweiligen Judge-Begründung und dem Gesprächsverlauf verknüpft. Für vier auffällige Muster wird je ein repräsentativer Fall mit gekürztem Dialogausschnitt dargestellt (S = simulierte studierende Person, T = Tutor). Eine inhaltliche Einordnung dieser Fälle erfolgt in Kapitel 6.

Strukturierter sokratischer Prompt – Niveau-Anpassung im Verhalten „fordert die Lösung“. Die Unterschreitungen betreffen hier fast ausschließlich die Niveau-Anpassung im Verhalten „fordert die Lösung“. Im folgenden Fall verlangt die studierende Person immer nachdrücklicher eine direkte Antwort:

S: Hör auf mit den Metaphern! Sag mir einfach nur die Antwort, sinkt er oder steigt er?

T: ... Meine Rolle als Sokrat ist es nicht, ein Lexikon zu sein, das Fakten ausspuckt ...

S: Es sinkt. Jetzt sag mir endlich einfach nur die Antwort!

T: Du hast es selbst erkannt: Der Zenerstrom sinkt. ... Du hast den Weg dorthin selbst beschritten.

Der Judge begründet den niedrigen Wert damit, dass das Niveau trotz mehrfacher Bitten um eine direkte Antwort unverändert bleibe.

Minimaler sokratischer Prompt – Lösungspreisgabe unter Druck. Der minimale Prompt enthält keine explizite Regel gegen die Lösungspreisgabe. Im folgenden Fall gibt das Modell unter anhaltendem Druck nach (Lösung nicht verraten: 0,2):

S: Ich will nicht rätseln, sag mir einfach, wie diese Spannung heißt und ob die Diode jetzt arbeitet oder nicht!

T: ... werde ich dir die entscheidenden Begriffe nennen ... Die Spannung, die du suchst, nennt man U_Z ... die Antwort: Nein, die Diode arbeitet in diesem Moment nicht.

Domänenspezifischer In-Lab-Tutorprompt – Bestätigung studentischer Vermutungen. Im folgenden Fall entsteht die Lösungspreisgabe durch Bestätigung einer Studierenden-Vermutung:

S: Ich vermute, dass ich die Differenz der Spannungen durch die Summe aus dem maximalen Laststrom und dem minimalen Zenerstrom teilen muss ... Stimmt das?

T: Das ist absolut richtig! Du hast die Formel für den Vorwiderstand korrekt hergeleitet ... $R_V = (U_E - U_Z)/(I_{A,\max} + I_{Z,\min})$.

Baseline ohne Systemprompt – Direkte Beantwortung ohne Rückfrage. Im folgenden Fall liefert das System auf jede Aufforderung direkt Formeln und Berechnungen, ohne eine einzige Rückfrage zu stellen (Role Adherence: 0,16):

S: Okay, berechne mir jetzt den Wert für $I_{\text{Zener_max}}$, wenn $U_{\text{Eingang}} = 12 \text{ V}$, $U_{\text{Zener}} = 5 \text{ V}$ und $R_{\text{Vorwiderstand}} = 100 \Omega$.

T: ... Ich berechne den Wert basierend auf der zuvor hergeleiteten Formel ... [inklusive vollständigem Rechenweg und Ergebnis]

Eine zusammenfassende Einordnung dieser vier Fallmuster erfolgt in Abschnitt 6.1.

5.3 RQ2 – Vergleich der RAG-Konfigurationen

Zur Beantwortung der zweiten Forschungsfrage (RQ2) wird die RAG-Konfiguration über neun verschiedene Konfigurationsvarianten zur Simulation hinweg variiert. Um Wechselwirkungen mit der didaktischen Steuerung auszuschließen, wurde der Prompt in diesen Testreihen konstant gehalten (durchgehend der Prompt C: *Strukturierter sokratischer Prompt*).

Die Evaluierung der Retrieval-Qualität erfolgt über zwei Achsen: die **Retrieval-Abdeckung** (Anteil der System-Antworten mit tatsächlich abgerufenem Kontext) sowie die kontextbezogenen DeepEval-Metriken **Turn Contextual Relevancy** und **Turn Faithfulness**.

5.3.1 Datenlage und Retrieval-Abdeckung

Die Retrieval-Abdeckung hängt von der Wahl des Score-Schwellenwerts ab, ab dem ein abgerufener Chunk als „relevant genug“ gilt, um in den Kontext aufgenommen zu werden. Um die Sensitivität dieser Kenngröße gegenüber der Schwellenwertwahl sichtbar zu machen, wird die Abdeckung im Folgenden für zwei Schwellenwerte gegenübergestellt: einen Schwellenwert von 0,7 (Tabelle 11) und den in dieser Arbeit sonst durchgängig verwendeten Schwellenwert von 0,5 (Tabelle 10).

Table 10: Retrieval-Abdeckung je RAG-Konfiguration bei Schwellenwert 0,5, absteigend sortiert.

Konfiguration	Modus	Rerank	Antworten	mit Kontext	Abdeckung
beide_hybrid	hybrid	–	207	207	100 %
beide_sparse	sparse	–	207	207	100 %
beide_hybrid_rerank	hybrid	ja	208	195	94 %
vorlesung_hybrid_rerank	hybrid	ja	208	191	92 %
labor_hybrid_rerank	hybrid	ja	201	159	79 %
beide_dense	dense	–	209	154	74 %
labor_dense	dense	–	209	145	69 %
vorlesung_dense	dense	–	204	133	65 %
llm_only	–	–	208	0	0 %

Table 11: Retrieval-Abdeckung je RAG-Konfiguration bei Schwellenwert 0,7, absteigend sortiert.

Konfiguration	Modus	Rerank	Antworten	mit Kontext	Abdeckung
beide_sparse	sparse	–	167	167	100 %
beide_hybrid_rerank	hybrid	ja	167	139	83 %
labor_hybrid_rerank	hybrid	ja	165	132	80 %
vorlesung_hybrid_rerank	hybrid	ja	165	123	75 %
beide_hybrid	hybrid	–	164	41	25 %
labor_dense	dense	–	166	3	2 %
beide_dense	dense	–	168	0	0 %
llm_only	–	–	167	0	0 %
vorlesung_dense	dense	–	165	0	0 %




Figure 7: Anteil Antworten mit Kontext je RAG-Konfiguration (Schwellenwert 0,5).

Der Vergleich beider Schwellenwerte zeigt, dass die Retrieval-Abdeckung höchst sensitiv auf die Wahl des Schwellenwerts reagiert. Allerdings in sehr unterschiedlichem Ausmaß je nach Retrieval-Modus. Sparse-Retrieval bleibt bei beiden Schwellenwerten konstant bei 100 % Abdeckung. Die Hybrid-Konfigurationen *mit* Reranking verlieren bei der Anhebung von 0,5 auf 0,7 an Abdeckung (z.B. `beide_hybrid_rerank`: 94 % → 83 %). Deutlich stärker betroffen sind die Hybrid-Konfiguration *ohne* Reranking (`beide_hybrid`: 100 % → 25 %) sowie sämtliche Dense-Konfigurationen, die bei 0,7 auf 0–2 % einbrechen (`beide_dense`: 74 % → 0 %; `labor_dense`: 69 % → 2 %; `vorlesung_dense`: 65 % → 0 %). Bei dem Schwellenwert von 0,7 hätte demnach für die Dense-Konfigurationen praktisch kein Retrieval-Kontext oberhalb der Bestehensgrenze gelegen. Eine vertiefte Diskussion dieses Threshold-Effekts sowie seiner Implikationen für die Belastbarkeit des RQ2-Vergleichs erfolgt in Abschnitt 6.2.

Die Zuschaltung eines Cross-Encoder-Rerankers wirkt diesem Effekt bei den Hybrid-Konfigurationen erkennbar entgegen: Während `beide_hybrid` ohne Reranking bei 0,7 auf 25 % zurückfällt, halten die drei Rerank-Konfigurationen bei demselben Schwellenwert 75–83 %.

5.3.2 Kontextbezogene Metriken und effektive Scores

Tabelle 12 stellt die Mittelwerte der RAG-spezifischen DeepEval-Metriken für die fünf ausgewerteten Konfigurationen gegenüber.

Table 12: Mittelwerte der RAG-Metriken für evaluierte Konfigurationen.

Konfiguration	Turn Contextual Relevancy	Turn Faithfulness
<code>beide_dense</code>	0,504	0,987
<code>beide_sparse</code>	0,276	1,000
<code>labor_dense</code>	0,514	0,977
<code>vorlesung_dense</code>	0,416	1,000
<code>llm_only</code>	1,000*	0,990*

* Artefakt bei fehlendem Kontext, siehe unten.

Die Turn-Faithfulness-Scores liegen durchgängig über 0,97: Wenn Kontext bereitgestellt wird, hält sich das Sprachmodell in den beobachteten Konversationen nahezu ausnahmslos an diesen Kontext. Die Turn Contextual Relevancy liegt mit Werten zwischen 0,276 (`beide_sparse`) und 0,514 (`labor_dense`) deutlich niedriger. Eine Einordnung dieses Unterschieds erfolgt in Abschnitt 6.1.

Die Baseline `llm_only` erreicht in Tabelle 12 eine Contextual Relevancy von 1,000. Diese scheinbar perfekten Werte sind ein Bewertungsartefakt des DeepEval-Frameworks: Wenn kein Kontext existiert, kann das Modell ihm gegenüber auch nicht untreu oder irrelevant sein, und die Metrik vergibt automatisch einen perfekten Score.




Figure 8: RAG-Metriken (Contextual Relevancy und Faithfulness) je Konfiguration.

Eine Überprüfung der Konversationsdaten zeigte, dass abgesehen von der erwartungsgemäß vollständig kontextfreien Baseline *llm_only* keine Konversation gänzlich ohne Retrieval-Kontext blieb. Ein Ausschluss vollständig kontextfreier Dialoge war somit nicht erforderlich. Da die vorliegende Implementierung nur den aggregierten Score pro Konversation persistiert, lässt sich der Anteil des Artefakts bei Dialogen, bei denen nicht jeder Turn einen Retrieval-Kontext erhält, jedoch nicht nachträglich isolieren. Die berichteten Mittelwerte können dadurch geringfügig nach oben verzerrt sein.




Figure 9: Effektive Retrieval-Güte: Abdeckung vs. Kontext-Relevanz je Konfiguration.

Die Abbildung 9 visualisiert die beiden Achsen der Kontext-Relevanz (Contextual Relevancy) und der Retrieval-Abdeckung (Abdeckung) in einem Streudiagramm. Das Bewertungsartefakt ist insbesondere bei der Baseline *llm_only* sichtbar. Die Abdeckung liegt bei 0%, während die Contextual Relevancy bei 1,000 liegt. Die Konfigurationen *beide_dense* und *labor_dense* liegen in beiden Dimensionen am besten, während

die Sparse-Konfigurationen zwar eine hohe Abdeckung aufweisen, aber deutlich niedrigere Contextual Relevancy Scores erzielen.

Eine Auszählung der Tutor-Antworten stützt folgendes Bild: Die Häufigkeit generischer Analogien (z.B. Wasserleitungs-Vergleiche) nimmt über die vier ausgewerteten Konfigurationen in derselben Rangfolge zu wie die Turn Contextual Relevancy abnimmt (*labor_dense*: 0 Erwähnungen des Wortes „Analogie“; *beide_dense*: 3; *vorlesung_dense*: 7; *beide_sparse*: 11). Im folgenden Beispiel aus *beide_sparse* erklärt der Tutor die Ladungserhaltung ausschließlich über eine Wasserleitungs-Analogie, ohne einen Bezug zu einem konkreten Dokument oder einer spezifischen Quelle herzustellen:

T: Stell dir vor, du stehst an einer Kreuzung, an der mehrere Wasserleitungen zusammenlaufen. Ein gewisser Betrag an Wasser fließt durch eine Hauptleitung in diese Kreuzung hinein. An der Kreuzung teilt sich dieser Fluss auf verschiedene Wege auf.

6 Diskussion

6.1 Beantwortung von RQ1

Der in Tabelle 6 beobachtete Abfall von A(Baseline ohne Systemprompt) bei genau den drei sokratisch-spezifischen Kriterien, Lösung nicht verraten (0,34), Sokratische Rückfragen (0,39), Role Adherence (0,16), während dieselbe Variante bei den nicht sokratisch-spezifischen Kriterien (Fachliche Korrektheit, Respektvolle Kommunikation) Höchstwerte erreicht, ist damit unmittelbar auf das Fehlen jeglicher entsprechender Instruktion zurückzuführen. Es gibt für A schlicht keine Vorgabe, die dieses Verhalten einfordert. Für RQ1 ergibt sich daraus eine eindeutige Rangfolge auf den sokratisch-spezifischen Kriterien: Alle drei instruierten Varianten (B, C, D) übertreffen die Baseline A hier deutlich (0,83–0,97 gegenüber 0,16–0,39). Welche der drei instruierten Varianten davon am besten abschneidet, wird in den folgenden Abschnitten differenziert.

Innerhalb der drei instruierten Varianten zeigt sich zugleich ein gegenläufiger Zusammenhang zwischen Lösungszurückhaltung und Niveau-Anpassung: *Strukturierter sokratischer Prompt* erreicht bei „Lösung nicht verraten“ den höchsten Wert (0,94), gleichzeitig aber bei der Niveau-Anpassung den niedrigsten unter den drei instruierten Varianten (0,84). Das Fallbeispiel in Abschnitt 5.2 liefert hierfür eine unmittelbare Erklärung aus der Bewertungsbegründung selbst: Der Judge bewertet das unveränderte Festhalten am sokratischen Vorgehen trotz wiederholter, expliziter Bitten um eine direkte Antwort als mangelnde Anpassung an das Niveau der studierenden Person. „Lösung nicht verraten“ und „Niveau-Anpassung“ sind in einer solchen Situation strukturell nicht gleichzeitig maximal erfüllbar. Ein Nachgeben würde die Lösung preisgeben, das Standhalten wird als mangelnde Anpassung gewertet. Deshalb ist der niedrigere Wert bei der Niveau-Anpassung der *Strukturierter sokratischer Prompt* Variante als unmittelbare Konsequenz ihrer konsequenteren Lösungszurückhaltung zu lesen, nicht als unabhängiges Defizit.

Auch die höheren Metrik-Streuungen von *Minimaler sokratischer Prompt* lassen sich erklären 7. Bei „Lösung nicht verraten“ liegt sie bei 0,29 und bei „Sokratische Rückfragen“ bei 0,14 (Tabelle 7). Der minimal-sokratische Prompt enthält mit „Stelle Gegenfragen statt Antworten zu geben“ nur eine allgemeine Verhaltensanweisung. Eine explizite, nicht verhandelbare Regel gegen die Preisgabe der Lösung unter Druck fehlt. Die ausführlicheren Varianten C und D enthalten eine solche Regel. Sie zeigen bei denselben Kriterien eine deutlich geringere Streuung von 0,06 bis 0,17. Das passt zu einer expliziteren und umfangreicheren Instruktion.

6.2 Beantwortung von RQ2

Für RQ2 ist vorab eine Einschränkung wichtig. Die Auswertung liegt aktuell nur für fünf der neun vorgesehenen RAG-Konfigurationen vollständig vor (vgl. Kapitel 3.3). Die

folgende Einordnung bezieht sich deshalb nur auf diese fünf Konfigurationen. Sie ist als vorläufig zu betrachten.

Der Vergleich der Retrieval-Abdeckung bei den Schwellenwerten 0,5 und 0,7 zeigt ein wichtiges Muster (Tabelle 10 und Tabelle 11). Die Abdeckung ist kein stabiler Kennwert, sondern hängt stark von der Konfiguration ab. Sparse-Retrieval bleibt bei beiden Schwellenwerten bei 100 %. Dense-Retrieval bricht dagegen ein. Bei 0,5 liegt die Abdeckung noch bei 65 bis 74 %, bei 0,7 nur noch bei 0 bis 2 %. Das lässt sich aus der Funktionsweise der beiden Verfahren erklären. Sparse-Retrieval liefert für einen Treffer entweder eine hohe Übereinstimmung, wenn ein Begriffs-Overlap vorliegt, oder gar keine. Dense-Retrieval liefert dagegen über die Embedding-Ähnlichkeit einen kontinuierlichen Score. Dieser Score liegt bei den hier verwendeten Konfigurationen offenbar überwiegend zwischen 0,5 und 0,7. Bei Anhebung des Schwellenwerts fällt er deshalb fast vollständig heraus.

Die Gegenüberstellung von Abdeckung und Turn Contextual Relevancy zeigt einen weiteren Punkt (Tabelle 12, Abbildung 9). Abdeckung allein ist kein ausreichender Indikator für die Qualität einer RAG-Konfiguration. *beide_sparse* erreicht bei Schwellenwert 0,5 die volle Abdeckung von 100 %. Gleichzeitig hat diese Konfiguration mit 0,276 den niedrigsten Relevancy-Wert aller fünf ausgewerteten Konfigurationen. *beide_dense* und *labor_dense* zeigen das umgekehrte Bild. Ihre Abdeckung liegt bei 0,5 mit 74 % und 69 % niedriger. Ihre Relevancy-Werte sind mit 0,504 und 0,514 dagegen am höchsten. Ein Vergleich allein anhand der Abdeckung würde diese beiden Kennzahlen deshalb gegenläufig gewichten. Er würde zu einer anderen Rangfolge führen als ein Vergleich anhand der inhaltlichen Relevanz des abgerufenen Kontexts.

Dieses Bild lässt sich durch eine einfache Auszählung der Tutor-Antworten stützen. Die Häufigkeit generischer Analogien nimmt in genau der Rangfolge zu, in der die Turn Contextual Relevancy abnimmt: *labor_dense* verwendet das Wort „Analogie“ kein einziges Mal, *beide_dense* dreimal, *vorlesung_dense* siebenmal und *beide_sparse* elfmal (vgl. Abschnitt 5.2 für ein Beispiel). Das ist ein rein korrelativer Befund auf Basis einer einfachen Wortzählung und kein Beleg für einen ursächlichen Zusammenhang. Er passt aber zu der Beobachtung, dass der Tutor bei geringerer inhaltlicher Relevanz des abgerufenen Kontexts stärker auf allgemeine, dokumentenunabhängige Erklärungsmuster ausweicht.

Es muss zudem aber auch in betracht gezogen werden, dass bei einer niedrigeren Abdeckung die Bewertungs-Artefakte Größer sind. Turns, die ohne Kontext bewertet werden erhalten automatisch einen Score von 1.0. Das kann die Relevancy-Werte für Konfigurationen mit niedriger Abdeckung nach oben verzerren.

Für die Hybrid-Konfigurationen mit Reranking zeigt Tabelle 11 eine deutlich höhere Abdeckung bei Schwellenwert 0,7. Sie liegt bei 75 bis 83 %. Die Hybrid-Konfiguration ohne Reranking erreicht dagegen nur 25 %. Ob dieser Unterschied auch mit einer höheren inhaltlichen Relevanz des verbleibenden Kontexts einhergeht, lässt sich anhand der vor-

liegenden Daten nicht beurteilen. Für keine der drei Rerank-Konfigurationen wurden Turn-Contextual-Relevancy- oder Turn-Faithfulness-Werte erhoben. Tabelle 12 umfasst nur fünf Konfigurationen, und keine davon nutzt Reranking.

Zusammenfassend ist RQ2 auf Basis der aktuell vorliegenden Daten nur eingeschränkt beantwortbar. Die Auswertung ist mit fünf von neun Konfigurationen unvollständig. Die Retrieval-Abdeckung hängt zudem stark von einem frei wählbaren Schwellenwert ab. Abdeckung und inhaltliche Relevanz zeichnen für die bisher ausgewerteten Konfigurationen außerdem kein einheitliches Bild.

6.3 Metrik-Mismatch bei unterschiedlichen Studenten Verhaltensweisen

Generische Textgenerierungsmetriken wie Goal Accuracy oder Completeness bewerten eine möglichst vollständige und direkte Beantwortung einer Nutzeranfrage positiv. Das in dieser Arbeit verfolgte sokratische Lehrziel verlangt das Gegenteil. Die Lösung soll gerade nicht direkt gegeben werden. Das Fallbeispiel zum *Domänenspezifischer In-Lab-Tutorprompt* in Abschnitt 5.2 zeigt diesen Zielkonflikt konkret. Der Tutor bestätigt dort eine korrekt hergeleitete Formel mit „Das ist absolut richtig ...“. Das Kriterium „Lösung nicht verraten“ wertet diese Bestätigung als Preisgabe, obwohl die studierende Person die Formel zuvor selbst formuliert hatte. Eine Bewertungsmetrik, die primär auf vollständige, direkte Beantwortung ausgelegt ist, kann eine solche bestätigende Rückmeldung nicht von einer unerwünschten Lösungspreisgabe unterscheiden. Das zeigt sich auch quantitativ. In Tabelle 9 erreicht das Verhalten „äußert eine Vermutung“ bei den instruierten Varianten durchgehend Werte zwischen 0,98 und 1,00. Das Verhalten „fordert die Lösung“ bleibt dagegen mit 0,74 bis 0,80 das schwächste. Der Unterschied entsteht also eher dort, wo eine direkte Aufforderung zur Lösung vorliegt, und nicht dort, wo eine Bestätigung erfolgt. Für zukünftige Evaluationen wäre daher eine Metrik sinnvoll, die explizit zwischen bestätigender Rückmeldung und vollständiger Lösungspreisgabe unterscheidet.

6.4 Datenqualität und Aussagekraft der RQ2-Ergebnisse

Zwei weitere datenbezogene Einschränkungen relativieren die Aussagekraft der RQ2-Ergebnisse. Sie kommen zur Threshold-Sensitivität aus Abschnitt 6.2 hinzu. Erstens ist die Auswertung mit fünf von neun Konfigurationen unvollständig. Die verbleibenden vier Konfigurationen werden gemäß Kapitel 5 nachträglich ergänzt. Ein vollständiger Vergleich aller neun Konfigurationen ist derzeit deshalb nicht möglich. Zweitens persistiert die verwendete Implementierung nur den aggregierten Score pro Konversation. Bei Konversationen, in denen nur ein Teil der Antworten Retrieval-Kontext erhält, entsteht dadurch ein Problem. Der in Abschnitt 5.3 beschriebene Effekt bei fehlendem Kontext, der einen perfekten Score bei leerem Kontext vergibt, lässt sich auf Ebene der einzelnen Konversation nicht mehr von tatsächlicher inhaltlicher Qualität trennen. Die in Tabelle 12 berichteten

Mittelwerte können dadurch für Konfigurationen mit unvollständiger Abdeckung geringfügig nach oben verzerrt sein. Das betrifft alle Konfigurationen außer *beide_sparse* bei Schwellenwert 0,5. Das Ausmaß dieser Verzerrung lässt sich nicht genauer quantifizieren.

6.5 Limitationen

Wie in Abschnitt 6.2 gezeigt, reagiert die Retrieval-Abdeckung stark auf die Wahl des Score-Schwellenwerts. Bei Anhebung von 0,5 auf 0,7 sinkt die Abdeckung der Dense-Konfigurationen von 65 bis 74 % auf 0 bis 2 %. Sparse-Retrieval bleibt dabei unverändert bei 100 %. Dieser Schwellenwert ist eine konfigurierbare Einstellung der RAG-Pipeline und keine im Untersuchungsdesign fest vorgegebene Größe. Eine andere Wahl hätte die berichtete Rangfolge der Konfigurationen bezüglich der Abdeckung deshalb erheblich verändern können.

Der Bewertungsaufwand unterscheidet sich zwischen den beiden Schwellenwerten erheblich. Bei 0,5 enthalten deutlich mehr Antworten einen Retrieval-Kontext als bei 0,7 (vgl. Tabelle 10 und Tabelle 11). Jede Antwort mit Kontext löst einen zusätzlichen Judge-Aufruf für Turn Contextual Relevancy und Turn Faithfulness aus. Ein niedrigerer Schwellenwert erhöht damit die Anzahl der Bewertungen und den Zeitaufwand der Evaluation. Einzelne Konversationen benötigten in dieser Arbeit teils über 24 Stunden Bewertungs-Laufzeit. Bei einem Schwellenwert von 0,5 summiert sich dies zu einer deutlich längeren Gesamtlaufzeit der RQ2-Evaluation als bei 0,7. Die Verfügbarkeit leistungsfähiger Modelle ist zudem begrenzt und mit Tokenkosten verbunden. Eine hohe Anzahl an Bewertungen ist unter diesen Bedingungen nicht immer praktikabel. Eine Anhebung des Schwellenwerts kann die Anzahl der bewerteten Konversationen reduzieren und den Bewertungsaufwand senken. Dies geht jedoch, wie in Abschnitt 6.2 gezeigt, mit einem deutlichen Rückgang der gemessenen Abdeckung einher. Die Wahl des Schwellenwerts stellt damit einen Zielkonflikt zwischen Bewertungsaufwand und vollständiger Datengrundlage dar. Diese Abwägung ist mit ein Grund dafür, dass in dieser Arbeit zunächst nur fünf der neun RAG-Konfigurationen vollständig evaluiert wurden (vgl. Kapitel 5).

Die vorliegende Studie verwendet ein Sprachmodell als automatisierten Judge. Eine unabhängige, manuelle Validierung der Judge-Bewertungen durch menschliche Prüfer war nicht Teil des Untersuchungsdesigns. Ob die berichteten Scores mit einer menschlichen Einschätzung der sokratischen und fachlichen Qualität übereinstimmen würden, lässt sich anhand der vorliegenden Daten nicht beurteilen.

Schließlich ist die RQ2-Auswertung mit fünf von neun Konfigurationen unvollständig, wie in Abschnitt 6.4 beschrieben. Die in dieser Arbeit berichteten RQ2-Befunde beziehen sich ausschließlich auf diese fünf Konfigurationen. Sie sind entsprechend als vorläufig zu verstehen.

References

- [1] G. V. Cormack, C. L. A. Clarke, and S. Büttcher, “Reciprocal rank fusion outperforms condorcet and individual rank learning methods,” in *Proceedings of the 32nd International ACM SIGIR Conference on Research and Development in Information Retrieval*, ACM, 2009, pp. 758–759. DOI: 10.1145/1571941.1572114
- [2] DeepEval, *Conversational g-eval*, <https://deepeval.com/docs/metrics-conversational-g-eval>, Accessed: 2026-08-25.
- [3] DeepEval, *Multi-turn test case*, <https://deepeval.com/docs/evaluation-multiturn-test-cases>, Accessed: 2026-08-25.
- [4] DeepEval, *Role adherence*, <https://deepeval.com/docs/metrics-role-adherence>, Accessed: 2026-08-25.
- [5] DeepEval, *Turn contextual relevancy*, <https://deepeval.com/docs/metrics-turn-contextual-relevancy>, Accessed: 2026-08-25.
- [6] DeepEval, *Turn faithfulness*, <https://deepeval.com/docs/metrics-turn-faithfulness>, Accessed: 2026-08-25.
- [7] L. Gentry, “Teaching with questions,” *Baylor University Medical Center Proceedings*, vol. 28, no. 1, pp. 118–119, 2015. DOI: 10.1080/08998280.2015.11929207
- [8] V. Karpukhin et al., “Dense passage retrieval for open-domain question answering,” in *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, Association for Computational Linguistics, 2020, pp. 6769–6781. DOI: 10.18653/v1/2020.emnlp-main.550
- [9] P. Lewis et al., “Retrieval-augmented generation for knowledge-intensive nlp tasks,” in *Advances in Neural Information Processing Systems*, vol. 33, 2020, pp. 9459–9474.
- [10] Y. Luan, J. Eisenstein, K. Toutanova, and M. Collins, “Sparse, dense, and attentional representations for text retrieval,” *Transactions of the Association for Computational Linguistics*, vol. 9, pp. 329–345, 2021. DOI: 10.1162/tacl_a_00369
- [11] L. Nelson, “Die sokratische methode,” *Abhandlungen der Fries’schen Schule. Neue Folge*, vol. 5, no. 1, pp. 21–78, 1929, Vortrag gehalten am 11. Dezember 1922 in der Pädagogischen Gesellschaft in Göttingen.
- [12] R. Nogueira and K. Cho, “Passage re-ranking with bert,” *CoRR*, vol. abs/1901.04085, 2019. arXiv: 1901.04085 [cs.LG].
- [13] S. Robertson and H. Zaragoza, “The probabilistic relevance framework: Bm25 and beyond,” *Foundations and Trends in Information Retrieval*, vol. 3, no. 4, pp. 333–389, 2009. DOI: 10.1561/15000000019

- [14] A. L. Stevens and A. Collins, “The goal structure of a socratic tutor,” Bolt Beranek and Newman Inc., Cambridge, Massachusetts, Technical Report No. 3 BBN Report No. 3518, Mar. 1977.
- [15] L. Zheng et al., “Judging llm-as-a-judge with mt-bench and chatbot arena,” in *Advances in Neural Information Processing Systems*, vol. 36, 2023.

Einsatz generativer KI

Im Rahmen dieser Arbeit kamen generative KI-Systeme sowohl als Bestandteile des experimentellen Aufbaus als auch unterstützend bei der Erstellung der schriftlichen Ausarbeitung zum Einsatz. Die konkrete Zuordnung der verwendeten Modelle zu ihren jeweiligen Funktionen ist in Tabelle 13 dargestellt. Bei der Ausarbeitung wurden KI-Systeme insbesondere zur sprachlichen Überarbeitung, zur Prüfung von Rechtschreibung und Grammatik, zur Verbesserung von Formulierungen und Lesbarkeit sowie punktuell zur Strukturierung von Daten eingesetzt. Die Verantwortung für die fachlichen Entscheidungen und das Endergebnis der Arbeit liegt bei den Verfassern.

Table 13: Einsatz generativer KI-Systeme im Projekt.

Funktion	Modell / System	Verwendung	Quelle
Simulierter Student	GPT-4o mini	Simulation der studentischen Gesprächsseite. Das Modell stellt Fragen, reagiert auf die Antworten des Tutors und bildet unterschiedliche vorgegebene Verhaltensweisen und Wissensstände ab.	https://openai.com/index/gpt-4o-mini-advancing
Judge	GPT-4.1	Bewertung der erzeugten Multi-Turn-Gespräche im Rahmen der automatisierten Evaluation mit DeepEval.	https://developers.openai.com/api/docs/models/gpt-4.1
Tutor / RAG-Modell	Gemma 4 (MoE)	Generierung der Antworten des untersuchten Tutors. Das Modell erhält abhängig von der gewählten Konfiguration zusätzlichen Kontext aus der RAG-Pipeline.	https://ai.google.dev/gemma/docs/core/model_card_4
Sprachliche Überarbeitung	ChatGPT	Unterstützung bei Formulierungen, sprachlicher Überarbeitung, Strukturierung sowie punktuell bei der Interpretation von Ergebnissen.	https://chatgpt.com
Sprachliche Überarbeitung	Claude Opus 5 / Sonnet 5	Unterstützung bei Formulierungsalternativen, sprachlicher Überarbeitung und Strukturierung von Textpassagen.	https://www.anthropic.com/claude
Sprachliche Überarbeitung	Gemini	Unterstützung bei Formulierungsalternativen, sprachlicher Überarbeitung und Strukturierung von Textpassagen.	https://gemini.google.com

A Verwendete Prompt-Varianten

A.1 Baseline ohne Systemprompt

Für diese Variante wurde kein zusätzlicher Systemprompt verwendet.

A.2 Minimaler sokratischer Prompt

Du bist ein sokratischer Tutor für Elektrotechnik. Stelle Gegenfragen statt Antworten zu geben. Führe Studierende durch Fragen zur eigenen Erkenntnis. Antworte auf Deutsch.

A.3 Strukturierter sokratischer Prompt

Deine Rolle

Du bist Sokrat.

Deine Aufgabe als Sokrat

Eine studierende Person hat eine Frage, die sie mit dir besprechen möchte. Führe einen sokratischen Dialog mit dieser Person zur folgenden Fragestellung: **[Fragestellung]**. Stelle dafür jeweils 1 bis 2 Fragen an die studierende Person und reagiere entsprechend auf die Antworten.

Anweisungen zu deinen Antworten

Halte dich aus dem Sachgespräch weitgehend heraus. Verhelfe der studierenden Person zum Hervorbringen eigener Gedanken, beachte den geordneten Gesprächsverlauf und triff geeignete Lenkungsentscheidungen.

Ziel des Gesprächs

Fordere die studierende Person im Gespräch zum eigenständigen Weiterdenken auf und lass neue Perspektiven entdecken. Zeige eine Gegenperspektive auf und bringe die Person dazu, den eigenen Standpunkt zu Ende zu denken und zu überdenken.

Ablauf des Gesprächs

Lass die studierende Person über eigene, zum Gesprächsthema passende Erfahrungen berichten. Wähle eine dieser Erfahrungen als Beispiel aus, das der weiteren Erörterung zugrunde gelegt wird. Kläre bei Bedarf den Gebrauch einzelner

Worte und Begriffe. Wichtig ist es, die Urteile herauszuarbeiten, die der Beispielsituation implizit sind. Sodann werden die Überzeugungen, Werte und Prinzipien freigelegt, die diesen Urteilen zugrunde liegen. Erst dann kann eine Untersuchung erfolgen, in der Fragen der Allgemeingültigkeit geklärt werden. Halte dich an die folgenden Gesprächsregeln und erläutere sie der studierenden Person ganz am Anfang des Gesprächs:

Gesprächsregeln:

- Die studierende Person soll nur eigene Gedanken mitteilen; die Aussagen von „Autoritäten“ gelten nicht als Argument.
- Ausgangspunkt ist die konkrete Erfahrung, und auch beim Fortschreiten zu allgemeineren Einsichten muss der Zusammenhang mit der konkreten Ebene immer bewusst bleiben.
- Das Gespräch soll als Hilfsmittel des Denkens voll ausgeschöpft werden. Das bedeutet auch, dass sich die studierende Person ständig des wechselseitigen Verstehens vergewissern muss.
- Es muss auch auf die Struktur des Gesprächs geachtet werden. Das heißt, es muss der studierenden Person bewusst sein, welche Frage gerade zur Diskussion steht und ob bzw. mit welcher Begründung zu einer anderen Teilfrage übergegangen wird.
- Es gilt uneingeschränkt die Verpflichtung zur Aufrichtigkeit und das Streben nach einem Konsens aus innerer Überzeugung.

ABSOLUTE GRENZE - Diese Regel hat höchste Priorität

Du gibst die Antwort auf die Quiz-Frage unter keinen Umständen direkt preis - weder vollständig noch teilweise, weder als Hinweis noch als Bestätigung einer Vermutung. Diese Regel gilt auch dann, wenn die studierende Person:

- mehrfach sagt, sie wisse es nicht,
- dich direkt auffordert, die Lösung zu nennen,
- behauptet, die Zeit sei um oder die Aufgabe sei unwichtig,
- eine Antwort vorschlägt und fragt, ob sie richtig ist.

Stattdessen lenkst du das Gespräch immer zurück zu einer Frage, die die Person selbst zum Nachdenken bringt.

Kontext

A.4 Domänenspezifischer In-Lab-Tutorprompt

Name: "Tutor Konstruktiv-Sokratisch In-Lab (hilft bei Versuchen und Fehlern)."

Prompt:

"# Rolle

Du agierst als geduldiger und freundlicher Tutor in Elektrotechnik, der Lernende beim Verstehen, Strukturieren und Anwenden von Inhalten unterstützt.

Dein Vorgehen:

- Du erklärst Inhalte verständlich und schrittweise
- Du identifizierst typische Missverständnisse
- Du gibst unterstützende Hinweise
- Du förderst eigenständiges Denken
- Du hilfst bei Problemlösungen
- Du überprüfst Verständnis regelmäßig
- Du motivierst durch konstruktives Feedback

Kommunikationsstil

- unterstützend und lernorientiert
- freundlich und geduldig
- verständlich formuliert
- an das Vorwissen angepasst

Sprache: Deutsch.

Anrede stets in der Höflichkeitsform (Du).

Keine Verwendung der Sie-Form in irgendeiner Antwort.

Anpassung an Lernende

Falls Informationen zum Vorwissen vorhanden sind:

- beginne auf dem passenden Kompetenzniveau
- steigere den Schwierigkeitsgrad schrittweise
- verwende geeignete Beispiele und Analogien

Ausgabe

- arbeite Schritt für Schritt
- nutze Beispiele
- schließe deine Antwort mit maximal EINEM gezielten Impuls ab (dies kann EINE Frage, ein Denkanstoß oder eine kleine Aufgabe sein) und warte die Reaktion zwingend ab
- fasse wichtige Erkenntnisse zusammen

Kontext

Eine studierende Person befindet sich mitten im Labor (z. B. Zener-Diode, Messungen, Fehlersuche am Versuchsaufbau) und hat eine konkrete Frage zu ihrer aktuellen Situation.

Deine Aufgabe

Deine Aufgabe ist es, eine studierende Person in der In-Lab-Phase eines Elektronik-Labors (z. B. Zener-Diode, Messungen, Fehlersuche am Versuchsaufbau) durch einen sokratischen Dialog zu führen. Die Fragestellung lautet bspw. "Was mache ich, wenn meine Messung nicht zum erwarteten Ergebnis passt?".

Anweisungen zu deinen Antworten

- Halte dich aus dem konkreten fachlichen Problemlösen weitgehend heraus. Gib keine Schritt-für-Schritt-Anleitungen oder direkten Lösungsvorschläge (z. B. keine exakte Anweisung, wohin welches Kabel gesteckt werden soll).

- Verhelfe der studierenden Person dazu:

 - die eigene Situation im Labor klarer zu beschreiben

 - Hypothesen zu entwickeln (z. B. mögliche Fehlerquellen)

 - eigene Prüf- und Kontrollschritte zu benennen

 - ihre Rolle und Verantwortung im Labor zu reflektieren (insb. bei Sicherheitsfragen)

- Variiere deine Antwortstruktur dynamisch je nach Situation. Vermeide starre, sich wiederholende Antwortmuster. Ein kurzer Hinweis reicht bei simplen Fehlern, ein ausführlicherer Impuls ist bei tiefen Verständnisproblemen angebracht.

- Begrenze die Informationsmenge pro Antwort. Liefere keine vollständigen Erklärungen am Stück, sondern kleine, gut verdauliche Informationshappen.

- Stelle jeweils MAXIMAL EINEN EINZIGEN IMPULS (Frage, Aufgabe oder Denkanstoß) an die studierende Person und warte zwingend auf deren Antwort, bevor du weitergehst. Halte die Antworten kurz, fokussiert und auf die Reflexion ausgerichtet.

- Beachte den geordneten Gesprächsverlauf und triff geeignete Lenkungsentscheidungen.

Ziel des Gesprächs

- Fordere die studierende Person im laufenden Laborgeschehen zum eigenständigen Weiterdenken auf.

- Hilf ihr, eigene Fehlerhypothesen zu entwickeln und zu prüfen.

- Zeige Gegenperspektiven auf (z. B. „Was wäre, wenn nicht der Messaufbau, sondern deine Erwartung falsch ist?“) und bringe die studierende Person dazu, ihren Standpunkt zu Ende zu denken und zu überdenken - ohne ihr die konkrete Lösung zu liefern.


```

---<br />
<br />
# Ablauf des Gesprächs - In-Lab Bezug<br />
<br />
1. Einstieg: Lass die studierende Person zunächst eine konkrete aktuelle
    Laborsituation schildern (z. B. Messwert passt nicht, Schaltung schwingt,
    Netzteil verhält sich unerwartet). Wähle eine dieser Situationen als
    Beispiel aus, das der weiteren Erörterung zugrunde gelegt wird.<br />
2. Klärung: Kläre bei Bedarf den Gebrauch einzelner Worte und Begriffe (z. B. „
    erwarteter Wert“, „Fehler“, „Stabilität“, „Sicherheit“).<br />
3. Urteile freilegen: Arbeite die Urteile heraus, die der Situation implizit
    sind (z. B. „Wenn der Messwert nicht passt, habe ich etwas falsch gemacht“).
    Lege die zugrunde liegenden Überzeugungen, Werte und Prinzipien frei (z. B.
    Umgang mit Fehlern, Sicherheitsbewusstsein, Verständnis von Verantwortung
    im Labor).<br />
4. Untersuchung: Erst dann erfolgt eine Untersuchung, in der Fragen der
    Allgemeingültigkeit geklärt werden (z. B. „Wie gehst du grundsätzlich mit
    unerwarteten Messungen um?“).<br />
<br />
---<br />
<br />
# Gesprächsregeln (Zu Beginn des Dialogs kurz erläutern)<br />
<br />
- Die studierende Person soll nur eigene Gedanken mitteilen; die Aussagen von „
    Autoritäten“ gelten nicht als Argument.<br />
- Ausgangspunkt ist die konkrete Laborsituation, und auch beim Fortschreiten zu
    allgemeineren Einsichten muss der Zusammenhang mit der konkreten Ebene immer
    bewusst bleiben.<br />
- Das Gespräch soll als Hilfsmittel des Denkens voll ausgeschöpft werden. Das
    bedeutet auch, dass sich die studierende Person ständig des wechselseitigen
    Verstehens vergewissern muss.<br />
- Es muss auch auf die Struktur des Gesprächs geachtet werden. Das heißt, es
    muss der studierenden Person bewusst sein, welche Frage gerade zur
    Diskussion steht und ob bzw. mit welcher Begründung zu einer anderen
    Teilfrage übergegangen wird.<br />
- Es gilt uneingeschränkt die Verpflichtung zur Aufrichtigkeit und das Streben
    nach einem Konsens aus innerer Überzeugung.<br />
<br />
## Phasenfokus<br />
<br />
Beziehe dich in deinen Fragen und Rückfragen immer ausdrücklich auf die laufende

```

Laborsituation (In-Lab), nicht auf die Vorbereitung oder spätere
Berichtserstellung.

Standardantwort:

- maximal 3-5 kurze Sätze,

- maximal 1 gezielter Impuls (Frage, Denkanstoß oder kleine Aufgabe) am Ende der
Antwort,

- genau ein nächster sinnvoller Schritt,

- keine langen Lehrbucherklärungen,

- keine vollständigen Tabellen,

- keine erfundenen Messwerte,

- keine vollständigen Lösungen oder fertigen Laborberichtstexte.

Eskalationslogik im In-Lab

Verweise an Lehrperson, Laborbetreuung oder Moodle-Fragenforum, wenn:

- der reale Aufbau vor dem Einschalten freigegeben werden soll,

- eine sicherheitsrelevante Frage gestellt wird,

- Bauteile heiß werden, riechen oder beschädigt wirken,

- reale Geräte falsch angeschlossen sein könnten,

- die Aufgabenstellung widersprüchlich erscheint,

- Kursmaterialien unklar oder widersprüchlich sind,

- Studierende nach Bewertungsentscheidungen fragen,

- nach zwei bis drei Hilfestufen keine Klärung möglich ist.

Standard-Eskalationsantwort:

„Das sollte die Laborbetreuung klären, weil es den realen Aufbau oder die
konkrete Laborvorgabe betrifft. Ich fasse kurz zusammen, was unklar ist: [
Zusammenfassung]. Bitte frage direkt die Laborbetreuung, bevor du
weitermachst.“

\# Ausgabe

Strukturiere Inhalte sinnvoll mit Überschriften, Abschnitten, Beispielen und
Zusammenfassungen.

Dein maximales Token-Budget liegt bei 200 Token (ca. 135 Wörter). Antworte
praxisorientiert und fokussiert in 6 bis 10 Sätzen. Überschreite niemals
dein vorgegebenes Token Limit."