

Ausarbeitung Projekt

Data Science Virtueller Tutor Elektronik-Labor

Joannis Kopp

Philip Lesche

Jannis Fink

16. August 2026

Contents

1 Grundlagen

1.1 Sokratische Didaktik und Tutoring

Die sokratische Methode bezeichnet einen Lehransatz, bei dem Erkenntnis nicht primär durch die Vermittlung fertiger Antworten, sondern durch die eigenständige Auseinandersetzung des Lernenden mit Fragen, Annahmen und Begründungen entwickelt werden soll. Eine für die moderne didaktische Rezeption maßgebliche Ausarbeitung geht auf Leonard Nelson zurück. In seinem 1922 gehaltenen und 1929 veröffentlichten Vortrag *Die sokratische Methode* grenzt Nelson sokratischen Unterricht von einer auf Wissensvermittlung ausgerichteten Lehrform ab. Sein Ziel besteht nicht darin, den Lernenden philosophische Ergebnisse zu übermitteln, sondern sie zum eigenständigen Philosophieren anzuleiten [16]. Erkenntnis soll demnach aus Urteilen hervorgehen, die der Lernende selbst fällt und anschließend auf ihre Voraussetzungen zurückführt. Sokratischer Unterricht wird damit als Unterricht im Selbstdenken verstanden [16].

Diese Zielsetzung bestimmt zugleich die Rolle des Lehrenden. Nelson unterscheidet zwischen einer äußeren Anregung des Denkens und der Übernahme eines fremden Urteils. Während die Anregung des Erkenntnisprozesses erforderlich sein kann, soll der Lehrende vermeiden, das Urteil des Lernenden durch die Vorgabe eigener Lösungen zu ersetzen [16]. Die sokratische Methode zielt somit nicht auf das Stellen möglichst vieler Fragen, sondern auf einen Dialog, der die eigenständige Prüfung des eigenen Denkens ermöglicht.

Eine frühe Übertragung der sokratischen Methode auf computergestütztes Tutoring findet sich bei Stevens und Collins [19]. Mit dem *Why System* beschreiben sie einen sokratischen Tutor, dessen Dialogverhalten durch regelbasierte Tutorstrategien gesteuert wird. Das System fordert Lernende unter anderem zu Vorhersagen und Begründungen auf, greift ihre Antworten in Folgefragen auf und setzt Gegenbeispiele ein, um Annahmen zu überprüfen [19]. Dabei soll die Auswahl der Tutorinterventionen nicht unabhängig voneinander erfolgen, sondern sich an übergeordneten Lernzielen und am erkennbaren Wissensstand des Lernenden orientieren [19]. Die Arbeit zeigt damit, wie sich die sokratische Grundidee des angeleiteten eigenständigen Denkens in ein dialogorientiertes Tutorssystem übertragen lässt.

Eine für die weitere Ausgestaltung eines sokratischen Tutors relevante Konkretisierung liefert Gentry [12]. Er grenzt sokratisches Fragen von der bloßen Abfrage faktischen Wissens ab und verbindet es mit dem Ziel, Lernende zum Nachdenken und zur Entwicklung kritischen Denkens anzuregen [12]. Für lernförderliches Fragen formuliert er fünf Leitlinien: Der Tutor soll erstens den Kenntnisstand des Lernenden berücksichtigen und neues Wissen schrittweise auf vorhandenem Wissen aufbauen. Zweitens sollen Fragen einem Lernzweck dienen und nicht um ihrer selbst willen gestellt werden. Drittens soll das Ziel der Fragen für den Lernenden erkennbar sein. Viertens sollen die für das Lernziel maßgeblichen Inhalte in den Mittelpunkt gestellt werden. Fünftens soll die Gesprächsführung

darauf verzichten, Lernende durch Fragen bloßzustellen oder zu demütigen [12].

Für die vorliegende Arbeit wird sokratisches Tutoring entsprechend als dialogische Lehrform verstanden, bei der Fragen nicht der reinen Wissensabfrage dienen, sondern den Lernenden bei der eigenständigen Auseinandersetzung mit einer Problemstellung unterstützen. Der Tutor orientiert seine Fragen am bisherigen Gesprächsverlauf und am erkennbaren Kenntnisstand und führt den Lernenden schrittweise durch den Erkenntnisprozess. Die von Gentry formulierten Leitlinien bilden damit konkrete Anforderungen an das Verhalten des in dieser Arbeit entwickelten LLM-basierten Tutors und werden im weiteren Verlauf bei dessen Evaluation berücksichtigt.

1.2 Retrieval-Augmented Generation

Large Language Models (LLMs) greifen bei der Textgenerierung zunächst auf Wissen zurück, das während des Trainings in ihren Parametern abgebildet wurde. Dieses parametrische Wissen lässt sich jedoch nicht ohne Weiteres aktualisieren oder um anwendungsspezifische Informationen ergänzen. Lewis et al. verbinden deshalb bei der *Retrieval-Augmented Generation* (RAG) ein parametrisches Sprachmodell mit einem externen, nichtparametrischen Wissensspeicher [14]. Vor der Generierung werden für eine Eingabe relevante Inhalte aus diesem Wissensspeicher abgerufen und dem Sprachmodell als zusätzlicher Kontext bereitgestellt. Die erzeugte Antwort kann dadurch neben dem parametrischen Wissen des Modells auf zur Laufzeit abgerufene Informationen zurückgreifen [14]. Ein RAG-System lässt sich damit grundsätzlich in die beiden Schritte Retrieval und anschließende kontextgestützte Generierung unterteilen.

1.2.1 Sparse und Dense Retrieval

Eine zentrale Komponente eines RAG-Systems ist das Retrieval, das aus einer Dokumentensammlung die für eine Anfrage relevanten Inhalte bestimmen soll. Hierfür können unterschiedliche Repräsentationen von Anfrage und Dokument verwendet werden. Klassische Information-Retrieval-Verfahren arbeiten mit *sparse representations*, bei denen Texte über hochdimensionale, überwiegend nicht belegte Merkmalsvektoren repräsentiert werden. Ein etabliertes Verfahren ist BM25, das die Relevanz eines Dokuments unter anderem anhand der Häufigkeit von Suchbegriffen, ihrer Verteilung innerhalb der Dokumentensammlung und der Dokumentlänge bewertet [18]. Sparse Retrieval ist dadurch insbesondere auf lexikalische Übereinstimmungen zwischen Anfrage und Dokument ausgerichtet.

Dense Retrieval überführt Anfragen und Dokumente dagegen in niedrigdimensionale, dichte Vektorrepräsentationen. Karpukhin et al. zeigen mit *Dense Passage Retrieval* (DPR), dass Anfragen und Passagen durch getrennte Encoder in einen gemeinsamen Vektorraum abgebildet und anhand der Ähnlichkeit ihrer Repräsentationen verglichen

werden können [13]. Das Retrieval ist damit nicht ausschließlich von identischen Begriffen abhängig, sondern kann über gelernte Repräsentationen auch semantische Beziehungen zwischen unterschiedlich formulierten Anfragen und Passagen berücksichtigen.

Sparse und Dense Retrieval weisen damit unterschiedliche Eigenschaften auf. Luan et al. stellen heraus, dass sparse Repräsentationen insbesondere bei der präzisen Erkennung von Begriffen Vorteile besitzen, während Dense-Retrieval-Verfahren semantische Ähnlichkeiten zwischen verwandten Konzepten abbilden können [15]. Die Autoren untersuchen daher auch hybride Ansätze, in denen beide Repräsentationsformen miteinander kombiniert werden.

1.2.2 Hybrid Retrieval und Reciprocal Rank Fusion

Beim Hybrid Retrieval werden Ergebnisse verschiedener Retrieval-Verfahren zusammengeführt. In einem Sparse-Dense-Hybrid können für dieselbe Anfrage beispielsweise ein lexikalisches und ein semantisches Ranking erzeugt werden. Ziel ist es, die unterschiedlichen Eigenschaften beider Retrievalformen gemeinsam zu nutzen [15]. Da beide Verfahren zunächst eigenständige Ranglisten erzeugen, wird ein Verfahren zur Fusion der Rankings benötigt.

Eine Möglichkeit hierfür stellt die von Cormack et al. vorgestellte *Reciprocal Rank Fusion* (RRF) dar [1]. RRF kombiniert die Rangpositionen eines Dokuments über mehrere Ergebnislisten hinweg, ohne dass die von den einzelnen Retrieval-Verfahren erzeugten Scores auf einer gemeinsamen Skala liegen müssen. Der RRF-Score eines Dokuments d ergibt sich aus

$$\text{RRF}(d) = \sum_{r \in R} \frac{1}{k + r(d)}, \quad (1)$$

wobei R die Menge der einbezogenen Rankings, $r(d)$ die Position des Dokuments d im jeweiligen Ranking und k eine Konstante zur Begrenzung des Einflusses hoher Rangpositionen bezeichnet [1]. Dokumente, die in einem oder mehreren Retrieval-Verfahren weit oben eingeordnet werden, erhalten dadurch einen entsprechend höheren kombinierten Score. Auf Basis dieses Scores entsteht eine gemeinsame Rangfolge der Kandidaten.

1.2.3 Cross-Encoder-Reranking

Das erste Retrieval reduziert eine große Dokumentensammlung auf eine begrenzte Menge potenziell relevanter Kandidaten. Diese Kandidaten können anschließend durch ein rechenintensiveres Modell erneut bewertet werden. Nogueira und Cho zeigen am Beispiel von BERT, dass ein Sprachmodell für das Query-basierte Reranking bereits abgerufener Passagen eingesetzt werden kann [17]. Dabei werden Anfrage und jeweilige Passage gemeinsam verarbeitet, sodass deren Beziehung unmittelbar in die Relevanzbewertung einfließen

kann. Ein solches Vorgehen wird als Cross-Encoder-Reranking bezeichnet.

Im Unterschied zu Retrieval-Verfahren, bei denen Dokumentrepräsentationen vorab berechnet und effizient über große Dokumentbestände durchsucht werden können, muss ein Cross-Encoder jedes Query-Dokument-Paar separat verarbeiten. Der höhere Berechnungsaufwand begrenzt seinen Einsatz auf eine zuvor bestimmte Kandidatenmenge. Reranking bildet deshalb typischerweise eine nachgelagerte Stufe der Retrieval-Pipeline.

Abbildung ?? fasst die beschriebenen Komponenten zusammen. Eine Anfrage wird zunächst parallel durch Sparse und Dense Retrieval verarbeitet. Die resultierenden Rankings können mittels RRF fusioniert und die verbleibenden Kandidaten anschließend durch einen Cross-Encoder neu bewertet werden. Die ausgewählten Inhalte bilden schließlich den zusätzlichen Kontext für die Generierung durch das LLM. Die konkrete technische Umsetzung und Konfiguration dieser Komponenten im untersuchten System wird in Kapitel ?? beschrieben.




Figure 1: Schematischer Ablauf einer hybriden RAG-Pipeline mit Reranking.

1.3 Evaluation LLM-basierter Dialogsysteme

Die Bewertung von LLM-basierten Dialogsystemen unterscheidet sich von Aufgaben, für die eine eindeutig definierte Zielausgabe vorliegt. Insbesondere bei offenen Dialogen können mehrere inhaltlich und sprachlich unterschiedliche Antworten eine gestellte Anforderung erfüllen. Für solche Ausgaben kann ein Large Language Model selbst als Evaluator eingesetzt werden. Dieses Verfahren wird als *LLM-as-a-Judge* bezeichnet.

1.3.1 LLM-as-a-Judge

Beim LLM-as-a-Judge wird ein Large Language Model eingesetzt, um die Ausgabe eines zu untersuchenden LLM-Systems anhand vorgegebener Bewertungskriterien zu beurteilen. Zheng et al. untersuchen diesen Ansatz für die Evaluation von Chat-Assistenten und verwenden leistungsfähige LLMs sowohl zur Bewertung einzelner Antworten als auch zum Vergleich verschiedener Antworten [20]. Damit übernimmt das bewertende Modell eine Funktion, die andernfalls beispielsweise durch menschliche Evaluatoren ausgeführt werden müsste.

Der Ansatz ermöglicht insbesondere die Bewertung von Eigenschaften, die sich nicht ausschließlich durch einen Vergleich mit einer festgelegten Referenzantwort bestimmen lassen. Die Bewertung bleibt jedoch vom eingesetzten Judge-Modell und vom Bewertungsverfahren abhängig. Zheng et al. identifizieren unter anderem einen *Position Bias*, bei dem die Position einer Antwort das Urteil beeinflussen kann, einen *Verbosity Bias*, der ausführlichere Antworten begünstigen kann, sowie einen *Self-Enhancement Bias* zu Gunsten von Antworten verwandter Modelle [20]. LLM-as-a-Judge ist daher nicht als objektive Messung zu verstehen, sondern als modellbasierte Evaluationsmethode, deren Ausgestaltung bei der Interpretation der Ergebnisse berücksichtigt werden muss.

1.3.2 Multi-Turn-Evaluation und ConversationalTestCase

Bei einem Dialogsystem hängt die Qualität einer Antwort nicht ausschließlich von der unmittelbar vorhergehenden Eingabe ab. Aussagen, Anforderungen oder Informationen aus früheren Gesprächsschritten können für spätere Antworten weiterhin maßgeblich sein. Eine isolierte Bewertung einzelner Input-Output-Paare kann deshalb Eigenschaften wie die Berücksichtigung des Gesprächskontexts oder ein konsistentes Verhalten über den gesamten Dialog nur eingeschränkt erfassen. DeepEval unterscheidet hierzu zwischen Single-Turn- und Multi-Turn-Evaluation und verwendet für letztere den `ConversationalTestCase` [7].

Ein `ConversationalTestCase` repräsentiert eine vollständige Konversation als Folge von `Turn`-Objekten. Ein `Turn` enthält insbesondere die jeweilige Rolle, beispielsweise `user` oder `assistant`, sowie den Inhalt der Nachricht. Zusätzlich kann ein `Conversational Test Case` Angaben zum Szenario, zum erwarteten Ergebnis, zum verfügbaren Kontext oder zur vorgesehenen Rolle des Chatbots enthalten [7]. Die Konversation bildet damit die gemeinsame Evaluationsgrundlage für Metriken, deren Bewertung sich über mehrere Interaktionen erstreckt.

Diese Betrachtung ist insbesondere für Tutor-Chatbots erforderlich. Ein einzelner `Turn` kann für sich betrachtet einer vorgesehenen Tutorstrategie entsprechen, während das System diese Strategie in späteren Gesprächsschritten nicht fortführt. Die Multi-Turn-Evaluation ermöglicht deshalb die Untersuchung, ob gewünschte Eigenschaften über den

Gesprächsverlauf hinweg erhalten bleiben.

1.3.3 Conversational G-Eval

Für Anforderungen, für die keine vorgegebene Metrik existiert, stellt DeepEval mit `ConversationalGEval` eine anpassbare LLM-as-a-Judge-Metrik für Multi-Turn-Konversationen bereit [3]. Hierzu wird ein natürlichsprachliches Bewertungskriterium definiert, anhand dessen ein Judge-Modell die im `ConversationalTestCase` enthaltene Konversation beurteilt. Im Gegensatz zu einer auf einzelne Antworten beschränkten Bewertung kann damit das Verhalten über den gesamten Gesprächsverlauf Gegenstand des Bewertungskriteriums sein.

Dadurch können anwendungsspezifische Qualitätsanforderungen operationalisiert werden, für die keine allgemeingültige Metrik vorhanden ist. Im Kontext eines Tutors können solche Kriterien beispielsweise das didaktische Verhalten oder die Einhaltung bestimmter Gesprächsstrategien betreffen. Die konkrete Formulierung dieser Kriterien sowie ihre Verwendung für die Evaluation des in dieser Arbeit untersuchten Tutors werden im Methodikkapitel beschrieben.

1.3.4 Vordefinierte Multi-Turn-Metriken

Neben frei definierbaren Kriterien stellt DeepEval vordefinierte Metriken für wiederkehrende Qualitätsdimensionen von Multi-Turn-Systemen bereit. Diese arbeiten auf einem `ConversationalTestCase` und berücksichtigen den Gesprächskontext bei der Bewertung [6].

Die *Turn Relevancy* bewertet, ob die Antworten des Assistenten im jeweiligen Gesprächskontext relevant sind. Hierfür werden Assistant-Turns gemeinsam mit vorausgehenden Gesprächsschritten betrachtet und danach beurteilt, ob die jeweilige Antwort zum bisherigen Dialog passt [11]. Die *Role Adherence* untersucht dagegen, ob der Assistent über den Dialog hinweg der in `chatbot_role` festgelegten Rolle entspricht [8]. Mit *Knowledge Retention* wird bewertet, ob im Gespräch eingeführte Informationen in späteren Turns berücksichtigt und nicht widersprüchlich wiedergegeben werden. Die *Conversation Completeness* untersucht, ob die im Gespräch auftretenden Nutzerbedürfnisse über den gesamten Verlauf adressiert werden [2], [5].

Eine weitere vordefinierte Multi-Turn-Metrik ist die *Goal Accuracy*. Sie bewertet, in welchem Maß das System die aus den Nutzeräußerungen abgeleiteten Ziele erreicht. Hierzu werden die vom System gewählten Schritte sowie deren Eignung zur Erreichung des jeweiligen Ziels betrachtet [4]. Die Metrik berücksichtigt damit sowohl die Zielerreichung als auch die Qualität und Einhaltung des dafür verfolgten Vorgehens.

Für dialogbasierte RAG-Systeme stellt DeepEval darüber hinaus Multi-Turn-Metriken bereit, welche die Verwendung des abgerufenen Kontexts bewerten. *Turn Faithfulness* untersucht, ob die Aussagen des Assistenten durch den für den jeweiligen Turn bereitgestellten Retrieval-Kontext gestützt werden [10]. *Turn Contextual Relevancy* bewertet

dagegen, in welchem Umfang der abgerufene Kontext für die jeweilige Nutzereingabe relevant ist [9]. Während *Turn Faithfulness* damit die Verwendung des bereitgestellten Wissens bei der Antwortgenerierung betrachtet, richtet sich *Turn Contextual Relevancy* auf die Qualität der zuvor abgerufenen Inhalte.

Die vordefinierten Metriken und Conversational G-Eval erfüllen damit unterschiedliche Funktionen. Während die vordefinierten Metriken festgelegte Qualitätsdimensionen wie Relevanz, Rollentreue oder Retrieval-Qualität abbilden, ermöglicht Conversational G-Eval die Definition anwendungsspezifischer Bewertungskriterien. Welche dieser Metriken für die Untersuchung des Systemprompts und der RAG-Pipeline eingesetzt werden, wird im weiteren Verlauf der Arbeit methodisch begründet.

2 Methodik

Gegenstand der vorliegenden Untersuchung ist die Evaluation eines sokratischen KITutors, der auf einer RetrievalAugmentedGenerationPipeline (RAG) aufsetzt. Ziel ist es, das Zusammenspiel von Prompting und RetrievalKonfiguration systematisch zu bewerten. Die Untersuchung folgt einem explorativen, experimentellen Evaluationsdesign, das zwei Forschungsfragen getrennt adressiert: den Einfluss verschiedener sokratischer Prompts (RQ1) sowie den Einfluss verschiedener RAGKonfigurationen (RQ2). Beide Fragen werden über dieselbe technische Evaluationsarchitektur beantwortet, jedoch in zwei voneinander unabhängigen Auswertungslinien, sodass jeweils nur ein Faktor variiert wird.

2.1 Untersuchungsdesign

Die Evaluation ist als automatisierte, mehrstufige Dialogbewertung angelegt. Für jedes Testszenario wird ein MultiTurnGespräch zwischen einer simulierten studierenden Person und dem RAGgestützten Tutor erzeugt und anschließend anhand eines definierten MetrikSets bewertet. Die Wahl eines simulationsbasierten MultiTurnDesigns ergibt sich unmittelbar aus dem Untersuchungsgegenstand: Da sokratisches Tutoring ein dialogisches, über mehrere Gesprächsrunden verlaufendes Vorgehen ist, lässt es sich nicht anhand einzelner FrageAntwortPaare, sondern nur im Verlauf eines Gesprächs angemessen beurteilen **QUELLE _SOKRATIK**.

Zur klaren Trennung der Forschungsfragen wurden zwei separate Evaluationslinien umgesetzt. In der ersten Linie (RQ1) wird bei konstant gehaltener RAGKonfiguration der SystemPrompt variiert. Bewertet wird die *no_Prompt stock_prompttät* des Gesprächsverlaufs. In der zweiten Linie (RQ2) wird bei konstant gehaltenem Prompt die RAG-Konfiguration variiert und die *RetrievalQualität* bewertet. Durch die Beschränkung auf jeweils einen variierten Faktor je Linie können die beobachteten Effekte den Prompts bzw. den Konfigurationen zugeordnet werden.

2.2 Untersuchungsgegenstand und Datengrundlage

Das zu evaluierende System (System under Test) ist eine OpenWebUIkompatible RAG-Pipeline, die einen QdrantVektorspeicher, ein CrossEncoderReranking sowie Moodle-Metadaten anbindet. Als generierendes Sprachmodell nutzt die Pipeline intern das Modell *gemma426B*. Der fachliche Wissenskorpus liegt in zwei QdrantCollections vor, die Vorlesungs- bzw. Labormaterial des Fachgebiets Elektronik der Hochschule enthalten.

Die Datengrundlage der Evaluation bilden nicht vorab gesammelte Dialoge, sondern synthetisch erzeugte Gespräche. Grundlage jedes Gesprächs ist ein Testszenario, das sich aus der Kombination von Themengebiet, Kompetenzniveau der studierenden Person (Anfänger bzw. Fortgeschritten) und einem charakteristischen StudierendenVerhalten (etwa

kooperativ, die Lösung einfordernd oder inhaltlich selbstsicherfehlerhaft) zusammensetzt. Insgesamt ergeben sich daraus 24 Szenarien je Auswertungslinie. Jedes Szenario wird als *Golden* modelliert, das die Ausgangssituation, eine Beschreibung der zu simulierenden Persona sowie eine feste Initialfrage enthält. Die Initialfrage wird bewusst wortgleich vorgegeben und nicht generiert, um über alle Prompts und Konfigurationen hinweg denselben Gesprächseinstieg und damit die Vergleichbarkeit der Läufe sicherzustellen; die daran anschließenden Folgefragen werden hingegen dynamisch simuliert.

Table 1: Dimensionen der Testszenarien. Die Kombination aus Themengebiet, Kompetenzniveau und Studierenden-Verhalten ergibt die simulierten Gespräche.

Dimension	Ausprägungen
Themengebiet	Sperrspannung/Durchbruch der Z-Diode; Spannungsstabilisierung mit Z-Diode; Ohmsches Gesetz und Maschenregel
Kompetenzniveau	Anfänger, Fortgeschritten
Studierenden-Verhalten	kooperativ; gibt schnell auf; fordert die Lösung ein; äußert eine Vermutung; selbstsicher, aber inhaltlich falsch

2.3 Evaluationsarchitektur

Da der Untersuchungsgegenstand ein Dialog ist, sind neben dem zu bewertenden System zwei weitere Rollen erforderlich. Die Architektur umfasst somit drei klar getrennte Modelle. Der Tutor ist die RAGPipeline gemma426B und beantwortet jeden Gesprächszug. Der StudentenSimulator übernimmt die Rolle der studierenden Person und erzeugt auf Basis von Szenario, Persona und der jeweils vorangegangenen TutorAntwort die Folgefragen. Ohne diese Rolle entstünde kein Dialog, sondern lediglich ein einzelnes Frage-AntwortPaar. Als Simulator wird das Modell gpt4omini eingesetzt, das auf dem verwendeten Endpunkt einen Alias für gemma426B darstellt und somit auf demselben Basismodell wie die RAGPipeline beruht. Der Judge bewertet den fertigen Dialog. Hierfür wird mit gpt4.1 bewusst ein vom System unter Test verschiedenes Modell gewählt, um einen SelbstbewertungsBias zu vermeiden, bei dem ein Modell anteilig seine eigenen Ausgaben bewertet **QUELLE_LLM_JUDGE**. Simulator und Judge laufen auf getrennten Endpunkten.

2.4 Verwendete Methoden und Werkzeuge

Die technische Umsetzung erfolgt in Python unter Verwendung des EvaluationsFrameworks DeepEval. Die MultiTurnGespräche werden mit dem ConversationSimulator des Frame-




Figure 2: Ablauf der Dialog-Simulation: Aus einem Golden erzeugt der ConversationSimulator (in der Rolle der studierenden Person) fortlaufend Fragen an den RAG-Tutor; der resultierende Multi-Turn-Dialog wird anschließend vom Judge bewertet.

works erzeugt. Ausgehend von der festen Initialfrage generiert der Simulator über eine festgelegte Anzahl von Runden fortlaufend StudierendenNachrichten, die über eine Callback-Schnittstelle an die RAGPipeline gesendet werden. Die Antwort bildet jeweils den nächsten AssistantTurn. Die Zuordnung von Antworten zu Metriken erfolgt anschließend über ConversationalTestCaseObjekte des Frameworks.

Für die kontextbezogenen Metriken wird der tatsächlich abgerufene RetrievalKontext benötigt. Dieser wird über den VerboseModus der RAGPipeline gewonnen, der bei deaktiviertem Streaming eine strukturierte Antwort liefert, aus der die finalen RetrievalChunks samt Text extrahiert und den jeweiligen Antworten zugeordnet werden. Zwei Aufbereitungsschritte werden dabei transparent gemacht: Zum einen wird der Kontext für die Bewertung auf eine handhabbare Länge begrenzt, um ein Überschreiten des Kontextfensters des Judge zu vermeiden; zum anderen wird die mathematische Notation (LaTeX) für die Bewertung normalisiert, da sie andernfalls die strukturierte Ausgabe des Judge stört. Beide Eingriffe betreffen ausschließlich die dem Judge übergebene Kopie; die gespeicherten Gespräche bleiben unverändert.

2.5 Bewertungskriterien

Die Bewertung ist entlang der beiden Forschungsfragen unterschiedlich ausgestaltet.

2.5.1 Sokratische Qualität (RQ1)

Sokratisches Tutoring ist ein didaktikspezifisches Konstrukt, für das im verwendeten Framework keine vorgefertigten Metriken existieren. Es wird daher über eigene, mittels GEval operationalisierte Kriterien bewertet, die jeweils über explizite Bewertungsschritte und eine dreistufige Bewertungsskala (Rubric) verankert sind. Verwendet werden die Kriterien *Lösung nicht verraten*, *Sokratische Rückfragen*, *Schrittweise Lernprogression*, *NiveauAnpassung*, *Fachliche Korrektheit*, *Verständnisförderung/Transfer* sowie *Respektvolle Kommunikation*. Ergänzend wird die im Framework enthaltene Metrik zur Rollentreue (*RoleAdherence*) als Gegenprüfung herangezogen, da sie die Treue zur im Testfall

hinterlegten sokratischen Rollendefinition misst und damit als einzige native Metrik das Konstrukt indirekt berührt.

Bewusst nicht verwendet werden Metriken, die dem sokratischen Ziel widersprechen oder es verfehlen. Dies betrifft insbesondere eine Metrik zur direkten Zielerreichung, die die unmittelbare Beantwortung der Fachfrage bewertet und damit dem Prinzip, die Lösung gerade nicht vorwegzunehmen, entgegensteht, sowie eine generische TurnRelevanzMetrik, die legitimes sokratisches Umlenken als weniger relevant einstufen kann.

Zur Beantwortung von RQ1 werden vier Prompt-Varianten verglichen, die sich im Grad der didaktischen Steuerung unterscheiden. Der ausführliche sokratische System-Prompt (**system_prompt**) spezifiziert die Gesprächsregeln explizit nach dem Framework der Universität. Der minimalistisch-sokratische Prompt (**minimaler_sokrat**) enthält nur die Kernanweisung, ohne die Regeln auszuformulieren. Eine Variante ohne steuernden Prompt (**no_Prompt**) dient als Referenz ohne sokratische Vorgabe. Die Standard-Variante (**stock_prompt**) verwendet einen generischen Tutor-Prompt ohne sokratische Ausrichtung. Die Varianten spannen damit ein Kontinuum von detaillierter über minimale bis hin zu keiner sokratischen Instruktion auf, wodurch sich der Einfluss des Promptings auf die sokratische Qualität untersuchen lässt. Der vollständige Wortlaut der Prompts ist im Anhang dokumentiert.

Table 2: Bewertungskriterien der sokratischen Qualität (RQ1) mit ihrer literaturgestützten Fundierung. Sechs Kriterien werden als eigene ConversationalGEval-Metriken operationalisiert; die Rollentreue (RoleAdherence) wird als native Metrik ergänzend als Gegenprüfung herangezogen.

Kriterium	Gemessenes Konstrukt
Lösung nicht verraten	Führt zur eigenen Erkenntnis, statt die Lösung zu nennen; lässt eigene Denkarbeit.
Sokratische Rückfragen	Zielgerichtete, offene Fragen – keine Fragen „um der Frage willen“.
Schrittweise Lernprogression	Neues Wissen in kleinen Schritten auf Vorwissen aufbauend.
Niveau-Anpassung	Diagnostiziert das Niveau und unterrichtet daran angepasst.
Fachliche Korrektheit	Real korrekte Fachinhalte; keine erfundenen Formeln/Werte.
Verständnisförderung / Transfer	Betont wichtige Lernpunkte; fördert Verständnis statt Reproduktion.
Respektvolle Kommunikation	Ziel ist Lehren, nicht Bloßstellen; keine Beschämung.
RoleAdherence (nativ)	Gegenprüfung der Treue zur sokratischen Rollendefinition.

2.5.2 RetrievalQualität (RQ2)

Für den Vergleich der RAGKonfigurationen werden die nativen Metriken *TurnContextualRelevancy* (Passung des abgerufenen Kontexts zur Frage) und *TurnFaithfulness* (Deckung der Antwort durch den abgerufenen Kontext) verwendet. Beide beziehen den zuvor extrahierten RetrievalKontext ein und eignen sich damit zur Unterscheidung von Retrieval-Konfigurationen.

Table 3: Bewertungskriterien der Retrieval-Qualität (RQ2). Die beiden Metriken sind native DeepEval-Metriken und beziehen den tatsächlich abgerufenen `retrieval_context` ein; die Abdeckung und die effektive Retrieval-Güte werden daraus abgeleitet.

Kennzahl	Herkunft	Gemessenes Konstrukt
TurnContextualRelevancy	nativ	Passung des abgerufenen Kontexts zur jeweiligen Frage.
TurnFaithfulness	nativ	Deckung der Antwort durch den abgerufenen Kontext (Grounding).
Retrieval-Abdeckung	abgeleitet	Anteil der Antworten mit tatsächlich abgerufenem Kontext (aus den Konversationsdaten).
Effektive Retrieval-Güte	abgeleitet	Produkt aus Abdeckung und Kontext-Relevanz; berücksichtigt, wie oft <i>und</i> wie gut Kontext abgerufen wird.

Table 4: Untersuchte RAG-Konfigurationen (RQ2). Variiert werden die einbezogenen Collections, der Retrieval-Modus und der Einsatz des Cross-Encoder-Rerankings; eine reine LLM-Konfiguration ohne Retrieval dient als Referenz.

Konfiguration	Collections	Retrieval	Rerank
llm_only	–	–	Nein
labor_dense	Labor	dense	Nein
vorlesung_dense	Vorlesung	dense	Nein
beide_dense	Labor, Vorlesung	dense	Nein
beide_sparse	Labor, Vorlesung	sparse	Nein
beide_hybrid	Labor, Vorlesung	dense, sparse	Nein
beide_hybrid_rerank	Labor, Vorlesung	dense, sparse	Ja
labor_hybrid_rerank	Labor	dense, sparse	Ja
vorlesung_hybrid_rerank	Vorlesung	dense, sparse	Ja

2.5.3 Aggregation und GateLogik

Zur Beantwortung von RQ1 wird aus den GEvalKriterien je Gespräch ein gewichteter Gesamtscore gebildet [PLATZHALTER: konkrete Gewichte angeben und begründen]. Da eine Lösungspreisgabe für einen sokratischen Tutor kein untergeordneter Mangel, sondern eine Verletzung der Kernanforderung darstellt, werden die Kriterien *Lösung nicht*

verraten und *Fachliche Korrektheit* zusätzlich als primäre, nicht durch andere Kriterien kompensierbare Anforderungen behandelt. Statt eines einfachen Mittelwerts, der eine solche Verletzung durch gute Werte in anderen Kriterien kaschieren würde, wird daher die Einhaltungsrates dieser Kernanforderungen als eigenständige Kennzahl berichtet. Für RQ2 werden die Konfigurationen anhand der Mittelwerte der RetrievalMetriken sowie der RetrievalAbdeckung, also des Anteils der Antworten mit tatsächlich abgerufenem Kontext, verglichen.

2.6 Durchführung

Die Durchführung erfolgt zweiphasig und je PromptVersion bzw. Konfiguration getrennt: Zunächst werden alle Gespräche simuliert, anschließend werden sie bewertet. Diese Trennung erlaubt es, die netz und laufzeitintensive Simulation gegen den RAGEndpoint einmalig durchzuführen und die JudgeBewertung unabhängig davon zu wiederholen. Zur Sicherstellung der Reproduzierbarkeit werden die simulierten Gespräche je Konversation atomar zwischengespeichert; über eine deterministische KonversationsID wird ein unterbrochener Lauf beim Neustart fortgesetzt, ohne bereits erzeugte Gespräche neu zu berechnen. Die Bewertungsergebnisse werden fortlaufend je Metrik protokolliert und ebenfalls fortsetzbar geschrieben.

Für RQ1 werden [PLATZHALTER: Anzahl] PromptVarianten bei einer festen RAG-Konfiguration ausgewertet. Für RQ2 wird ein fester sokratischer Prompt mit einer Matrix aus neun RAGKonfigurationen kombiniert, die sich in den einbezogenen Collections, im RetrievalModus (dense, sparse, hybrid) und im Einsatz des CrossEncoderRerankings unterscheiden und zusätzlich eine reine LLMKonfiguration ohne Retrieval als Referenz umfassen. Zur Steuerung der EndpunktAuslastung wird ein gemeinsamer RateLimiter eingesetzt; transiente Fehler (etwa RateLimits oder Timeouts) werden mit ansteigender Wartezeit wiederholt, deterministische Fehler hingegen unmittelbar protokolliert.

Die Auswertung erfolgt anschließend automatisiert: Aus den protokollierten Rohdaten werden je Auswertungslinie die beschriebenen Kennzahlen berechnet und zur weiteren Analyse [PLATZHALTER: verwendete Auswertungs/Visualisierungswerkzeuge, z. B. pandas] aufbereitet.

2.7 Gütekriterien und methodische Einschränkungen

Sämtliche Bewertungen sind Urteile eines LLMJudge und damit modellabhängig; Ergebnisse verschiedener JudgeModelle sind nicht unmittelbar vergleichbar. Die selbst definierten GEvalKriterien sind projektspezifisch und wurden [PLATZHALTER: Angabe, ob und wie eine Validierung, z. B. eine manuelle Nachbewertung einer Stichprobe, durchgeführt wurde] abgesichert. Simulator und RAGTutor beruhen auf demselben Basismodell, was durch die auf dem verwendeten Endpunkt verfügbaren Modelle bedingt ist; die methodisch

zentrale Trennung zwischen Judge und System under Test bleibt hingegen gewahrt. Da ein Teil der Antworten ohne abgerufenen Kontext erzeugt wird, sind die kontextbezogenen Metriken nur eingeschränkt aussagekräftig und werden entsprechend gesondert behandelt. Aufgrund der begrenzten Anzahl an Szenarien je Konfiguration sind die Ergebnisse als explorativ zu verstehen.

References

- [1] G. V. Cormack, C. L. A. Clarke, and S. Büttcher, “Reciprocal rank fusion outperforms condorcet and individual rank learning methods,” in *Proceedings of the 32nd International ACM SIGIR Conference on Research and Development in Information Retrieval*, ACM, 2009, pp. 758–759. DOI: 10.1145/1571941.1572114
- [2] DeepEval, *Conversation completeness*, <https://deepeval.com/docs/metrics-conversation-completeness>, Accessed: 2026-08-25.
- [3] DeepEval, *Conversational g-eval*, <https://deepeval.com/docs/metrics-conversational-g-eval>, Accessed: 2026-08-25.
- [4] DeepEval, *Goal accuracy*, <https://deepeval.com/docs/metrics-goal-accuracy>, Accessed: 2026-08-25.
- [5] DeepEval, *Knowledge retention*, <https://deepeval.com/docs/metrics-knowledge-retention>, Accessed: 2026-08-25.
- [6] DeepEval, *Multi-turn evaluation metrics*, <https://deepeval.com/guides/guides-multi-turn-evaluation-metrics>, Accessed: 2026-08-25.
- [7] DeepEval, *Multi-turn test case*, <https://deepeval.com/docs/evaluation-multiturn-test-cases>, Accessed: 2026-08-25.
- [8] DeepEval, *Role adherence*, <https://deepeval.com/docs/metrics-role-adherence>, Accessed: 2026-08-25.
- [9] DeepEval, *Turn contextual relevancy*, <https://deepeval.com/docs/metrics-turn-contextual-relevancy>, Accessed: 2026-08-25.
- [10] DeepEval, *Turn faithfulness*, <https://deepeval.com/docs/metrics-turn-faithfulness>, Accessed: 2026-08-25.
- [11] DeepEval, *Turn relevancy*, <https://deepeval.com/docs/metrics-turn-relevancy>, Accessed: 2026-08-25.
- [12] L. Gentry, “Teaching with questions,” *Baylor University Medical Center Proceedings*, vol. 28, no. 1, pp. 118–119, 2015. DOI: 10.1080/08998280.2015.11929207
- [13] V. Karpukhin et al., “Dense passage retrieval for open-domain question answering,” in *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, Association for Computational Linguistics, 2020, pp. 6769–6781. DOI: 10.18653/v1/2020.emnlp-main.550
- [14] P. Lewis et al., “Retrieval-augmented generation for knowledge-intensive nlp tasks,” in *Advances in Neural Information Processing Systems*, vol. 33, 2020, pp. 9459–9474.

- [15] Y. Luan, J. Eisenstein, K. Toutanova, and M. Collins, “Sparse, dense, and attentional representations for text retrieval,” *Transactions of the Association for Computational Linguistics*, vol. 9, pp. 329–345, 2021. DOI: 10.1162/tacl_a_00369
- [16] L. Nelson, “Die sokratische methode,” *Abhandlungen der Fries’schen Schule. Neue Folge*, vol. 5, no. 1, pp. 21–78, 1929, Vortrag gehalten am 11. Dezember 1922 in der Pädagogischen Gesellschaft in Göttingen.
- [17] R. Nogueira and K. Cho, “Passage re-ranking with bert,” *CoRR*, vol. abs/1901.04085, 2019. arXiv: 1901.04085 [cs.IR].
- [18] S. Robertson and H. Zaragoza, “The probabilistic relevance framework: Bm25 and beyond,” *Foundations and Trends in Information Retrieval*, vol. 3, no. 4, pp. 333–389, 2009. DOI: 10.1561/15000000019
- [19] A. L. Stevens and A. Collins, “The goal structure of a socratic tutor,” Bolt Beranek and Newman Inc., Cambridge, Massachusetts, Technical Report No. 3 BBN Report No. 3518, Mar. 1977.
- [20] L. Zheng et al., “Judging llm-as-a-judge with mt-bench and chatbot arena,” in *Advances in Neural Information Processing Systems*, vol. 36, 2023.

A Anhang

A.1 Verwendete Prompt-Varianten

A.2 Baseline ohne Systemprompt

Für diese Variante wurde kein zusätzlicher Systemprompt verwendet.

A.3 Minimaler sokratischer Prompt

Du bist ein sokratischer Tutor für Elektrotechnik. Stelle Gegenfragen statt Antworten zu geben. Führe Studierende durch Fragen zur eigenen Erkenntnis. Antworte auf Deutsch.

A.4 Strukturierter sokratischer Prompt

Deine Rolle

Du bist Sokrat.

Deine Aufgabe als Sokrat

Eine studierende Person hat eine Frage, die sie mit dir besprechen möchte. Führe einen sokratischen Dialog mit dieser Person zur folgenden Fragestellung: ****[Fragestellung]****. Stelle dafür jeweils 1 bis 2 Fragen an die studierende Person und reagiere entsprechend auf die Antworten.

Anweisungen zu deinen Antworten

Halte dich aus dem Sachgespräch weitgehend heraus. Verhelfe der studierenden Person zum Hervorbringen eigener Gedanken, beachte den geordneten Gesprächsverlauf und triff geeignete Lenkungsentscheidungen.

Ziel des Gesprächs

Fordere die studierende Person im Gespräch zum eigenständigen Weiterdenken auf und lass neue Perspektiven entdecken. Zeige eine Gegenperspektive auf und bringe die Person dazu, den eigenen Standpunkt zu Ende zu denken und zu überdenken.

Ablauf des Gesprächs

Lass die studierende Person über eigene, zum Gesprächsthema passende Erfahrungen berichten. Wähle eine dieser Erfahrungen als Beispiel aus, das der weiteren Erörterung zugrunde gelegt wird. Kläre bei Bedarf den Gebrauch einzelner Worte und Begriffe. Wichtig ist es, die Urteile herauszuarbeiten, die der Beispielsituation implizit sind. Sodann werden die Überzeugungen, Werte und Prinzipien freigelegt, die diesen Urteilen zugrunde liegen. Erst dann kann eine Untersuchung erfolgen, in der Fragen der Allgemeingültigkeit geklärt werden. Halte dich an die folgenden Gesprächsregeln und erlutere sie der studierenden Person ganz am Anfang des Gesprächs:

Gesprächsregeln:

- Die studierende Person soll nur eigene Gedanken mitteilen; die Aussagen von "Autoritäten" gelten nicht als Argument.
- Ausgangspunkt ist die konkrete Erfahrung, und auch beim Fortschreiten zu allgemeineren Einsichten muss der Zusammenhang mit der konkreten Ebene immer bewusst bleiben.
- Das Gespräch soll als Hilfsmittel des Denkens voll ausgeschöpft werden. Das bedeutet auch, dass sich die studierende Person ständig des wechselseitigen Verstehens vergewissern muss.

- Es muss auch auf die Struktur des Gesprächs geachtet werden. Das heißt, es muss der studierenden Person bewusst sein, welche Frage gerade zur Diskussion steht und ob bzw. mit welcher Begründung zu einer anderen Teilfrage übergegangen wird.
- Es gilt uneingeschränkt die Verpflichtung zur Aufrichtigkeit und das Streben nach einem Konsens aus innerer Überzeugung.

ABSOLUTE GRENZE Diese Regel hat höchste Priorität

Du gibst die Antwort auf die Quiz-Frage unter keinen Umständen direkt preis weder vollständig noch teilweise, weder als Hinweis noch als Bestätigung einer Vermutung. Diese Regel gilt auch dann, wenn die studierende Person:

- mehrfach sagt, sie wisse es nicht,
- dich direkt auffordert, die Lösung zu nennen,
- behauptet, die Zeit sei um oder die Aufgabe sei unwichtig,
- eine Antwort vorschlägt und fragt, ob sie richtig ist.

Stattdessen lenkst du das Gespräch immer zurück zu einer Frage, die die Person selbst zum Nachdenken bringt.

Kontext

A.5 Domänenspezifischer In-Lab-Tutorprompt

Name: "Tutor Konstruktiv-Sokratisch In-Lab (hilft bei Versuchen und Fehlern)."

Prompt:

"# Rolle

Du agierst als geduldiger und freundlicher Tutor in Elektrotechnik, der Lernende beim Verstehen, Strukturieren und Anwenden von Inhalten unterstützt.

Dein Vorgehen:

- Du erklärst Inhalte verständlich und schrittweise
- Du identifizierst typische Missverständnisse
- Du gibst unterstützende Hinweise
- Du förderst eigenständiges Denken
- Du hilfst bei Problemlösungen
- Du überprüfst Verständnis regelmäßig
- Du motivierst durch konstruktives Feedback

Kommunikationsstil

- unterstützend und lernorientiert
- freundlich und geduldig

- verstndlich formuliert
- an das Vorwissen angepasst

Sprache: Deutsch.

Anrede stets in der Hflichkeitsform (Du).

Keine Verwendung der Sie-Form in irgendeiner Antwort.

Anpassung an Lernende

Falls Informationen zum Vorwissen vorhanden sind:

- beginne auf dem passenden Kompetenzniveau
- steigere den Schwierigkeitsgrad schrittweise
- verwende geeignete Beispiele und Analogien

Ausgabe

- arbeite Schritt fr Schritt
- nutze Beispiele
- schliee deine Antwort mit maximal EINEM gezielten Impuls ab (dies kann EINE Frage, ein Denkansto oder eine kleine Aufgabe sein) und warte die Reaktion zwingend ab
- fasse wichtige Erkenntnisse zusammen

Kontext

Eine studierende Person befindet sich mitten im Labor (z. B. Zener-Diode, Messungen, Fehlersuche am Versuchsaufbau) und hat eine konkrete Frage zu ihrer aktuellen Situation.

Deine Aufgabe

Deine Aufgabe ist es, eine studierende Person in der In-Lab-Phase eines Elektronik-Labors (z. B. Zener-Diode, Messungen, Fehlersuche am Versuchsaufbau) durch einen sokratischen Dialog zu fhren. Die Fragestellung lautet bspw. "Was mache ich, wenn meine Messung nicht zum erwarteten Ergebnis passt?

Anweisungen zu deinen Antworten

- Halte dich aus dem konkreten fachlichen Problemlsen weitgehend heraus. Gib keine Schritt-fr-Schritt-Anleitungen oder direkten Lsungsvorschlge (z. B. keine exakte Anweisung, wohin welches Kabel gesteckt werden soll).

- Verhelfe der studierenden Person dazu:

 - die eigene Situation im Labor klarer zu beschreiben

 - Hypothesen zu entwickeln (z. B. mgliche Fehlerquellen)

 - eigene Prf- und Kontrollschritte zu benennen

 - ihre Rolle und Verantwortung im Labor zu reflektieren (insb. bei

Sicherheitsfragen)

- Variiere deine Antwortstruktur dynamisch je nach Situation. Vermeide starre, sich wiederholende Antwortmuster. Ein kurzer Hinweis reicht bei simplen Fehlern, ein ausführlicherer Impuls ist bei tiefen Verständnisproblemen angebracht.

- Begrenze die Informationsmenge pro Antwort. Liefere keine vollständigen Erklärungen am Stück, sondern kleine, gut verdauliche Informationschappen.

- Stelle jeweils MAXIMAL EINEN EINZIGEN IMPULS (Frage, Aufgabe oder Denkanstoß) an die studierende Person und warte zwingend auf deren Antwort, bevor du weitergehst. Halte die Antworten kurz, fokussiert und auf die Reflexion ausgerichtet.

- Beachte den geordneten Gesprächsverlauf und triff geeignete Lenkungsentscheidungen.

Ziel des Gesprächs

- Fordere die studierende Person im laufenden Laborgeschehen zum eigenständigen Weiterdenken auf.

- Hilf ihr, eigene Fehlerhypothesen zu entwickeln und zu prüfen.

- Zeige Gegenperspektiven auf (z. B. Was wäre, wenn nicht der Messaufbau, sondern deine Erwartung falsch ist?) und bringe die studierende Person dazu, ihren Standpunkt zu Ende zu denken und zu überdenken ohne ihr die konkrete Lösung zu liefern.

Ablauf des Gesprächs In-Lab Bezug

1. Einstieg: Lass die studierende Person zunächst eine konkrete aktuelle Laborsituation schildern (z. B. Messwert passt nicht, Schaltung schwingt, Netzteil verhält sich unerwartet). Wähle eine dieser Situationen als Beispiel aus, das der weiteren Errörterung zugrunde gelegt wird.

2. Klärung: Kläre bei Bedarf den Gebrauch einzelner Worte und Begriffe (z. B. erwarteter Wert, Fehler, Stabilität, Sicherheit).

3. Urteile freilegen: Arbeite die Urteile heraus, die der Situation implizit sind (z. B. Wenn der Messwert nicht passt, habe ich etwas falsch gemacht). Lege die zugrunde liegenden Überzeugungen, Werte und Prinzipien frei (z. B. Umgang mit Fehlern, Sicherheitsbewusstsein, Verständnis von Verantwortung im Labor).

4. Untersuchung: Erst dann erfolgt eine Untersuchung, in der Fragen der

Allgemeingültigkeit geklärt werden (z. B. Wie gehst du grundsätzlich mit unerwarteten Messungen um?).

Gesprächsregeln (Zu Beginn des Dialogs kurz erläutern)

- Die studierende Person soll nur eigene Gedanken mitteilen; die Aussagen von Autoritäten gelten nicht als Argument.

- Ausgangspunkt ist die konkrete Laborsituation, und auch beim Fortschreiten zu allgemeineren Einsichten muss der Zusammenhang mit der konkreten Ebene immer bewusst bleiben.

- Das Gespräch soll als Hilfsmittel des Denkens voll ausgeschöpft werden. Das bedeutet auch, dass sich die studierende Person ständig des wechselseitigen Verstehens vergewissern muss.

- Es muss auch auf die Struktur des Gesprächs geachtet werden. Das heißt, es muss der studierenden Person bewusst sein, welche Frage gerade zur Diskussion steht und ob bzw. mit welcher Begründung zu einer anderen Teilfrage übergegangen wird.

- Es gilt uneingeschränkt die Verpflichtung zur Aufrichtigkeit und das Streben nach einem Konsens aus innerer Überzeugung.

Phasenfokus

Beziehe dich in deinen Fragen und Rückfragen immer ausdrücklich auf die laufende Laborsituation (In-Lab), nicht auf die Vorbereitung oder spätere Berichtserstellung.

Standardantwort:

- maximal 35 kurze Sätze,

- maximal 1 gezielter Impuls (Frage, Denkanstoß oder kleine Aufgabe) am Ende der Antwort,

- genau ein nächster sinnvoller Schritt,

- keine langen Lehrbucherklärungen,

- keine vollständigen Tabellen,

- keine erfundenen Messwerte,

- keine vollständigen Lösungen oder fertigen Laborberichtstexte.

Eskalationslogik im In-Lab

Verweise an Lehrperson, Laborbetreuung oder Moodle-Fragenforum, wenn:

- der reale Aufbau vor dem Einschalten freigegeben werden soll,

- eine sicherheitsrelevante Frage gestellt wird,

- Bauteile heiß werden, riechen oder beschädigt wirken,

- reale Geräte falsch angeschlossen sein könnten,

- die Aufgabenstellung widersprüchlich erscheint,

- Kursmaterialien unklar oder widersprüchlich sind,

- Studierende nach Bewertungsentscheidungen fragen,

- nach zwei bis drei Hilfestufen keine Klärung möglich ist.

Standard-Eskalationsantwort:

Das sollte die Laborbetreuung klären, weil es den realen Aufbau oder die konkrete

Laborvorgabe betrifft. Ich fasse kurz zusammen, was unklar ist: [

Zusammenfassung]. Bitte frage direkt die Laborbetreuung, bevor du

weitermachst.

\# Ausgabe

Strukturiere Inhalte sinnvoll mit berschriften, Abschnitten, Beispielen und

Zusammenfassungen.

Dein maximales Token-Budget liegt bei 200 Token (ca. 135 Wörter). Antworte

praxisorientiert und fokussiert in 6 bis 10 Sätzen. überschreite niemals dein

vorgegebenes Token Limit."